

Fundamentos de Analítica de Datos Financieros

Parte III | Econometría Financiera

Víctor Macías E.

Población vs. Muestra

En la práctica financiera nunca observamos la población real, sino subconjuntos de datos llamados **muestras**. La definición de ambas depende de la estructura de los datos analizados:

1. Corte Transversal (*Cross-Sectional Data*)

Analiza múltiples entidades en *un punto del tiempo*.

- *Población (N)*: El universo completo de entidades de interés.

Ejemplos: Todas las startups *fintech* de Latinoamérica o la totalidad de deudores hipotecarios de un banco.

- *Muestra (n)*: El subconjunto de entidades recolectadas u observadas para el estudio.

Ejemplos: Las 150 *fintechs* que respondieron una encuesta o 10.000 créditos seleccionados al azar de la cartera.

2. Series de Tiempo (*Time Series Data*)

Analiza *una misma entidad o variable* a lo largo del tiempo.

- *Población: El proceso generador de datos (DGP).* El conjunto abstracto de todas las trayectorias que una variable pudo o podría haber tomado.
- *Muestra: La serie histórica observada.* La única trayectoria concreta de la variables que se terminó realizando dentro de las infinitas posibilidades, capturada en días, meses o años.

3. Datos de Panel (*Panel Data / Longitudinal*)

Combina ambas dimensiones: sigue a N entidades a lo largo de T periodos de tiempo (obteniendo un total de $N \times T$ observaciones).

- *Población ($N \times T \rightarrow \infty$): El proceso generador de datos conjunto.* El marco estocástico que gobierna simultáneamente la heterogeneidad entre las entidades y su evolución temporal.
- *Muestra ($n \times t$): La matriz de datos observada.* El conjunto de n entidades (empresas, países, etc.) seguidas durante t periodos de tiempo ($n \leq N, t \leq T$).

Parámetro poblacional y estadístico muestral

El objetivo central de la inferencia estadística es utilizar la información de una muestra para estimar el valor verdadero pero desconocido de la población.

Parámetro Poblacional (El valor verdadero)

Es una constante que describe una característica de toda la población. Es fijo pero desconocido, ya que en la práctica es casi imposible observar a la población, a menos que se realice un censo. Algunos ejemplos:

- *Media poblacional (μ):* El retorno esperado o de largo plazo de un activo.
- *Desviación estándar poblacional (σ):* La volatilidad de los retornos de un portafolio de mercado.
- *Proporción poblacional (p):* La tasa de morosidad de todo el sistema crediticio.

Estadístico muestral (estimado)

Se calcula a partir de los datos observados en una muestra. Es conocido y variable. Es conocido porque se calcula de los datos recolectados, pero es una variable aleatoria porque su valor cambia dependiendo de la muestra específica que se haya seleccionado (variabilidad muestral). Algunos ejemplos:

- *Media muestral ($\bar{x}$)*: El promedio de los retornos observados para un activo determinado en los últimos n días.
- *Desviación estándar muestral (s)*: La volatilidad calculada sobre la muestra histórica de retornos.
- *Proporción muestral ($\hat{p}$)*: El porcentaje de impagos observado en una muestra de 1.000 clientes.

Teorema del Límite Central (TLC)

A medida que el tamaño de la muestra (n) aumenta, la distribución muestral de las medias ($\bar{x}$) tomadas de diferentes muestras de una población se aproximara a una distribución normal. Se asume que las observaciones son independientes e idénticamente distribuidas.

Este comportamiento ocurre independientemente de la forma o distribución que tenga la población subyacente, incluso si no es normal.

Distribución muestral

- Para la media muestral ($\bar{x}$): Con un n adecuado, su distribución muestral sigue aproximadamente:

$$\bar{x} \sim \mathcal{N} \left(\mu, \frac{\sigma}{\sqrt{n}} \right)$$

- Para la proporción muestral ($\hat{p}$): Con un n adecuado, su distribución muestral sigue aproximadamente:

$$\hat{p} \sim \mathcal{N} \left(p, \sqrt{\frac{p(1-p)}{n}} \right)$$





Error estándar (ES)

El *error estándar* cuantifica la variabilidad muestral y la precisión con la que un estadístico (como la media o la proporción muestral) estima el verdadero parámetro de la población:

- Para la media muestral ($\bar{x}$): $ES(\bar{x}) = \frac{s}{\sqrt{n}}$
- Para la proporción muestral ($\hat{p}$): $ES(\hat{p}) = \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}$

En ambos casos, a mayor número de observaciones (n), menor es el error estándar. Esto se traduce en estimaciones más precisas y, por lo tanto, menores márgenes de incertidumbre para la toma de decisiones.

Rendimientos de portafolios con 1, 5, 30 y 500 activos



De la estimación puntual a la estimación por intervalos

Hasta ahora hemos estudiado la estimación puntual: usar la media muestral ($\bar{x}$) o la proporción muestral ($\hat{p}$) como la *mejor apuesta* para estimar el parámetro poblacional. Sin embargo, sabemos que debido a la variabilidad muestral, la estimación puntual casi nunca será idéntica al parámetro real.

 Proyectar un solo número genera una peligrosa ilusión de certeza. Los intervalos de confianza delimitan la incertidumbre en un rango medible, ofreciendo el margen de seguridad necesario para decidir con rigor.

Ejemplo 1:

El departamento de tesorería proyecta que el saldo de caja medio del próximo mes será de \$50 millones (estimación puntual). Sin embargo, un intervalo de confianza al 95% para la media le indica al Gerente de Finanzas que el saldo promedio se sitúa entre \$42 millones y \$58 millones.

Esta métrica sustituye la falsa certeza de una cifra única por un rango estadísticamente delimitado, permitiendo a la empresa planificar la cobertura de líneas de crédito necesarias para el escenario del límite inferior (\$42 millones).

¿Cómo construir un intervalo de confianza?

Un Intervalo de Confianza (IC) es un rango de valores razonables dentro del cual esperamos que se encuentre el valor del parámetro poblacional.

Un intervalo de confianza se construye como:

$$\text{Intervalo de Confianza} = \text{Estadístico Muestral} \pm \text{Margen de Error}$$

donde el *margen de error* depende de la precisión deseada y del *error estándar*:

$$\text{Margen de Error} = \text{Valor Crítico} \times \text{Error Estándar}$$

IC para la media poblacional (μ)

Cuando estimamos una media poblacional usando la distribución t de Student ($n < 100$ o σ desconocida):

$$\text{IC} = \bar{x} \pm t_{\alpha/2, n-1} \times \frac{s}{\sqrt{n}}$$

Si $n \geq 100$, por el TLC la *distribución t* converge a la *normal*.

IC para la proporción poblacional (p)

Cuando estimamos una proporción poblacional (usando la aproximación Normal z si $np \geq 10$ y $n(1 - p) \geq 10$):

$$\text{IC} = \hat{p} \pm z_{\alpha/2} \times \sqrt{\frac{\hat{p}(1 - \hat{p})}{n}}$$

El nivel de confianza y el valor crítico

El *nivel de confianza* (NC) representa la tasa de éxito a largo plazo del método utilizado para construir el intervalo.

NC	α	$z_{\alpha/2}$
90%	0.10	1.645
95%	0.05	1.960
99%	0.01	2.576

Nota que al aumentar el nivel de confianza se amplía el rango del intervalo, haciéndolo menos preciso pero más seguro.

¿Qué significa realmente 95% de *Confianza*?

Un error común de interpretación: decir que “hay un 95% de probabilidad de que el parámetro real caiga dentro de este intervalo específico” es técnicamente incorrecto (el parámetro está dentro del intervalo o no lo está).

La interpretación correcta es frecuentista: el 95% se refiere al proceso de estimación, no a un intervalo individual.

Adopción de un Producto Financiero

Supongamos que en un mercado de 2.4 millones de inversionistas, 900 mil han adoptado un nuevo ETF de Criptoactivos. La verdadera proporción poblacional de adopción es fija y conocida por nosotros para este experimento:

$$p = \frac{900.000}{2.400.000} = 0.375 \quad (37.5\%)$$

Supongamos que no conocemos p y enviamos a 100 analistas a estimarlo:

Paso 1: Cada analista extrae una muestra independiente de $n = 1000$ inversionistas..


Paso 2: Cada uno calcula su propia proporción muestral ($\hat{p}$).

Paso 3: Cada uno construye un IC al 95% mediante:

$$\hat{p} \pm 1.96 \times \sqrt{\frac{\hat{p}(1 - \hat{p})}{1000}}$$

Paso 4: Verificamos cuántos de los 100 intervalos contruidos lograron “atrapar” al valor del parámetro ($p = 0.375$).

Simulación de 100 Intervalos de Confianza al 95%



💡 Observa que aproximadamente 5 de los 100 intervalos no incluyen el verdadero parámetro poblacional $p = 0.375$ (representados en rojo). Por lo tanto, si se repite el proceso de muestreo 100 veces en las mismas condiciones, esperamos que aproximadamente 95 de esos intervalos contengan el valor verdadero del parámetro.

💡 Tener un *95% de confianza* no garantiza que el intervalo específico sea infalible; sólo significa que se está utilizando una metodología que, al aplicarse repetidamente bajo las mismas condiciones, acertará en el 95% de las ocasiones y fallará en el 5%.

Ejemplo 2:

Un fondo de inversión obtuvo un retorno promedio mensual de 1.2% con una desviación estándar mensual de 4.5% basada en 36 meses de datos.

Construye un intervalo de confianza al 95%.

- a. Compara los IC obtenidos usando las distribuciones t-Student y Normal.
- b. Si los datos corresponden a 120 meses, ¿hay diferencia en los IC contruidos usando las distribuciones t-Student y Normal? ¿Aumenta o disminuye el IC al aumentar el número de meses?

a. Si los datos corresponden a 36 meses:

```
1 mean_ret = 0.012
2 std_ret = 0.045
3 n = 36
4 alpha = 0.05
```

```
1 # Método 1
2 ic_inferior_t, ic_superior_t = stats.t.interval(0.95, df=n-1, loc=mean_ret, scale=std_ret/np.sqrt(n))
3 print(f"IC 95% (t-Student): [{ic_inferior_t:.2%}, {ic_superior_t:.2%}]")
4
5 ic_inferior_norm, ic_superior_norm = stats.norm.interval(0.95, loc=mean_ret, scale=std_ret/np.sqrt(n))
6 print(f"IC 95% (Normal): [{ic_inferior_norm:.2%}, {ic_superior_norm:.2%}]")
```

IC 95% (t-Student): [-0.32%, 2.72%]

IC 95% (Normal): [-0.27%, 2.67%]

```
1 # Método 2
2 t_critico = stats.t.ppf(alpha/2, df=n-1)
3
4 limite_inferior = mean_ret - abs(t_critico)*std_ret/np.sqrt(n)
5 limite_superior = mean_ret + abs(t_critico)*std_ret/np.sqrt(n)
6
7 print(f"Límite inferior: {limite_inferior:.2%}")
8 print(f"Límite superior: {limite_superior:.2%}")
```

Límite inferior: -0.32%

Límite superior: 2.72%

b. Si los datos corresponden a 120 meses:

```
1 # Distribución t-Student
2 ic_inferior, ic_superior = stats.t.interval(0.95, df=119, loc=mean_ret, scale=std_ret/np.sqrt(120))
3
4 print(f"IC 95% (t-Student): [{ic_inferior:.2%}, {ic_superior:.2%}]")
```

IC 95% (t-Student): [0.39%, 2.01%]

```
1 # Distribución normal
2 ic_inferior, ic_superior = stats.norm.interval(0.95, loc=mean_ret, scale=std_ret/np.sqrt(120))
3
4 print(f"IC 95% (Normal): [{ic_inferior:.2%}, {ic_superior:.2%}]")
```

IC 95% (Normal): [0.39%, 2.01%]

Nota que, en este caso, no hay diferencia en los IC construidos usando las distribuciones t-Student y normal ¿Por qué?

De los IC a las pruebas de hipótesis

En la sección anterior aprendimos que un *intervalo de confianza* nos da un rango de valores plausibles para un parámetro.

La *prueba de hipótesis* es la otra cara de la moneda: nos permite evaluar cuantitativamente una afirmación específica sobre ese parámetro.

Hipótesis Nula (H_0) e Hipótesis Alternativa (H_1)

- **Hipótesis Nula (H_0):** La postura del inversionista escéptico. Asume que “*No hay efecto*”, “*El retorno excedente es cero*” o “*El nuevo algoritmo no supera al benchmark*”.
- **Hipótesis Alternativa (H_1 o H_a):** La afirmación que requiere prueba suficiente. Representa la anomalía de mercado o el rendimiento extraordinario que el analista busca demostrar.



No Rechazar $H_0 \neq$ Aceptar H_0

No encontrar evidencia suficiente para demostrar que un trader tiene talento no prueba que sea incompetente; solo significa que sus resultados actuales son estadísticamente indistinguibles del azar.

Una analogía: Se presume inocente hasta que se pruebe lo contrario

H_0 : Persona es inocente

H_1 : Persona es culpable

La carga de la prueba está en la Fiscalía que debe presentar evidencia que persuada a los jueces de que la persona no es inocente.

¿Cómo formular H_0 y H_1 ?

- 1. Formuladas en términos de los parámetros poblacionales.**
Las hipótesis se plantean sobre el verdadero proceso generador de datos $(\mu, \sigma, \alpha, \beta)$, nunca sobre sus contrapartes muestrales $(\bar{x}, s, \hat{\alpha}, \hat{\beta})$.
- 2. Mutuamente exclusivas y, en conjunto, agotan el espacio de posibilidades.** No pueden cumplirse ambas al mismo tiempo, y entre las dos abarcan todo el espacio de posibilidades.
- 3. H_0 siempre contiene el signo de igualdad ($=, \leq, \geq$).** La igualdad representa el “status quo” o la falta de efecto.

Ejemplo 3:

Una cadena de retail evalúa si la implementación de la opción de pago “Cómpralo ahora, págalo después” (*Buy Now, Pay Later, BNPL*) incrementa el valor promedio del ticket de compra respecto al promedio histórico, el cual se sitúa en US\$85.

Parámetro de interés (μ): El valor promedio verdadero (poblacional) del ticket de compra de todos los clientes de la cadena que utilizan el método BNPL.

Formulación de hipótesis:

$H_0 : \mu \leq 85$ (El servicio BNPL no incrementa el ticket promedio respecto al histórico)

$H_1 : \mu > 85$ (El servicio BNPL incrementa significativamente el ticket promedio)

Tipo de prueba: Cola superior

Errores en la Toma de Decisiones

Dado que la inferencia estadística se realiza a partir de una muestra y está sujeta a la variabilidad muestral, siempre existe el riesgo de llegar a una conclusión equivocada.

Ejemplo 3 (Continuación)

Tras seleccionar una muestra aleatoria representativa de $n = 250$ transacciones realizadas con BNPL y calcular los estadísticos correspondientes, la gerencia se expone a cometer dos tipos de errores inferenciales:

- *Rechazar H_0 cuando H_0 es verdadera (Error Tipo I / Falso Positivo)*
- *No rechazar H_0 cuando H_0 es falsa (Error Tipo II / Falso Negativo)*

Rechazar H_0 cuando H_0 es verdadera (Error Tipo I / Falso Positivo):

Concluir que el servicio BNPL incrementa el ticket promedio cuando en realidad no genera ningún efecto.

- *Impacto de negocio:* Se asumen costos innecesarios de integración tecnológica, comisiones financieras y mantenimiento operativo sin obtener un retorno real sobre la inversión.

No rechazar H_0 cuando H_0 es falsa (Error Tipo II / Falso Negativo):

Concluir que el servicio BNPL no incrementa el ticket promedio y descartarlo, cuando en realidad sí incrementaba significativamente el valor de las compras.

- *Impacto de negocio:* Se incurre en un costo de oportunidad al perder ventas potenciales y desperdiciar una estrategia comercial efectiva.

Decisión	H_0 es Verdadera	H_0 es Falsa
Rechazar H_0	ERROR TIPO I Falso Positivo	Decisión Correcta
No Rechazar H_0	Decisión Correcta	ERROR TIPO II Falso Negativo

$$\alpha = P(\text{Error Tipo I}) = P(\text{Rechazar } H_0 \mid H_0 \text{ es verdadera})$$

$$\beta = P(\text{Error Tipo II}) = P(\text{No rechazar } H_0 \mid H_0 \text{ es falsa})$$

¿Cómo elegir el nivel de significancia (α)?

El α se ajusta según el costo de cometer un *Falso Positivo* (*Error Tipo I*) frente a un *Falso Negativo* (*Error Tipo II*).

Ejemplo 4: Modelo de riesgo de crédito ($\alpha = 0.01$ o 1%)

Objetivo: Evaluar si un nuevo modelo disminuye la proporción de impago/morosidad respecto al modelo actual.

Parámetro de interés (p): La tasa o proporción verdadera (poblacional) de impago/morosidad de los clientes aprobados bajo el nuevo modelo.

Tasa de impago histórica / actual (p_0): La proporción de impago observada bajo el modelo vigente en el banco.

Formulación de hipótesis:

$H_0 : p \geq p_0$ (El nuevo modelo no reduce la tasa de impago; la probabilidad de morosidad es igual o mayor que la del modelo actual).

$H_1 : p < p_0$ (El nuevo modelo disminuye la tasa de impago).

Tipo de prueba: Cola inferior

Criterio de Decisión ($\alpha = 0.01$): Solo se rechazará H_0 si la evidencia muestra que la tasa de impago del nuevo modelo es inferior a la actual con un nivel de confianza del 99%.

- *Error Tipo I (Falso Positivo)*: el banco concluye que el nuevo modelo de scoring reduce significativamente la morosidad y decide implementarlo, cuando en realidad la tasa de impago sigue siendo igual o mayor a la histórica. Por ello, el estándar de prueba exigido es sumamente estricto.
- *Error Tipo II (Falso Negativo)*: el análisis concluye que el nuevo modelo no funciona y se decide descartarlo, cuando en verdad el modelo sí reducía de forma efectiva la tasa de impago por debajo del nivel histórico.

Ejemplo 5: Detección de Fraude en tarjetas de crédito ($\alpha=0.10$ o 10%)

Objetivo: Probar si un nuevo algoritmo detecta una tasa de fraude superior a la del sistema actual para justificar su implementación.

Parámetro de interés (p): La tasa o proporción verdadera (poblacional) de transacciones fraudulentas identificadas correctamente por el nuevo algoritmo.

Tasa de detección histórica / actual (p_0): La proporción de transacciones fraudulentas detectadas bajo el sistema vigente en el banco.

Formulación de hipótesis:

$H_0 : p \leq p_0$ (El nuevo algoritmo no incrementa la tasa de detección; la tasa es menor o igual que la del sistema actual).

$H_1 : p > p_0$ (El nuevo algoritmo identifica una proporción mayor de transacciones fraudulentas que el sistema actual).

Tipo de prueba: Cola superior

Criterio de Decisión ($\alpha=0.10$): Se rechazará H_0 si la evidencia muestra que el nuevo algoritmo supera al actual con un nivel de confianza del 90%.

- *Error Tipo I (Falso Positivo)*: el banco concluye que el nuevo algoritmo es más efectivo para detectar fraudes cuando en realidad no genera ninguna mejora respecto al sistema actual. Cometer este error implica adoptar un modelo que puede provocar bloqueos temporales de tarjeta en compras legítimas, generando quejas de los clientes.
- *Error Tipo II (Falso Negativo)*: el análisis concluye que el nuevo algoritmo no funciona y se decide descartarlo, cuando en verdad el modelo sí detectaba una mayor cantidad de fraudes. Cometer este error resulta crítico, pues el banco mantiene un sistema deficiente y asume el costo directo de los fraudes no detectados. Por ello, se relaja el nivel de prueba ($\alpha = 0.10$) para minimizar los falsos negativos.

¿Cómo implementar un contraste de hipótesis?

- Método del valor-p
- Método del valor crítico
- Método del intervalo de confianza (en pruebas de hipótesis de dos colas)

Método del valor-p (p-value)

El *p-value* es la probabilidad de haber obtenido un resultado tan o más extremo que el observado en la muestra, asumiendo que la hipótesis nula (H_0) es verdadera.

La regla de decisión es:

Si $\text{p-value} \leq \alpha \Rightarrow$ Se rechaza H_0

Si $\text{p-value} > \alpha \Rightarrow$ No se rechaza H_0

Método del valor crítico

Se compara el valor de un estadístico de prueba con un valor crítico para decidir si se rechaza o no H_0 .

Estadístico de prueba. Es alguna función de la muestra aleatoria. Por ejemplo, en contrastes de hipótesis de la media poblacional, el estadístico de prueba es:

$$t = \frac{\bar{x} - \mu_0}{s/\sqrt{n}} \sim t_{n-1}$$

En muestras grandes, puedes usar la distribución normal.

Valor crítico. Se determina mediante la distribución del estadístico de prueba, asumiendo que H_0 sea verdadera y depende del nivel de α .

Se rechazará H_0 si el valor absoluto del valor calculado para el estadístico de prueba es mayor al valor absoluto del valor crítico.

Método del intervalo de confianza

$$H_0 : \mu = \mu_0$$

$$H_1 : \mu \neq \mu_0$$

En un **contraste de hipótesis de dos colas**, se rechaza H_0 si el intervalo de confianza no incluye a μ_0 .

Nota: El contraste de hipótesis de dos colas también puede plantearse para otros parámetros poblacionales.

Ejemplo 6:

Un analista financiero afirma que una acción tecnológica de alta volatilidad genera un rendimiento en exceso (prima de riesgo) respecto a la tasa libre de riesgo (R_f) significativamente superior a cero. Para verificarlo, se auditan los rendimientos excedentes mensuales de la acción ($R_i - R_f$) durante los últimos 60 meses (5 años), obteniendo un rendimiento medio en exceso de 0.8% mensual y una desviación estándar del 2.1%.

Plantea las hipótesis nula y alternativa y evalúa si la evidencia valida la afirmación del analista, usando un nivel de significancia del 1%.

Formulación de Hipótesis:

$H_0: \mu \leq 0$ (El rendimiento en exceso medio no es superior a cero)

$H_1: \mu > 0$ (El rendimiento en exceso medio es significativamente mayor a cero)

Tipo de prueba: Cola superior

```

1 # Datos de la muestra
2 mean_exceso = 0.008 # 0.8% mensual
3 s = 0.021          # 2.1% desviación estándar
4 n = 60             # 60 meses
5 alpha = 0.01       # Nivel de significancia fijado al 1%
6
7 t_critico = stats.t.ppf(1-alpha, df=n-1)
8 t_stat = (mean_exceso - 0) / (s / np.sqrt(n)) # Estadístico t de una muestra
9 p_value_right = 1 - stats.t.cdf(t_stat, df=n-1) # p-valor para prueba de cola superior
10
11 print(f"Estadístico t (valor crítico): {t_critico:.3f}")
12 print(f"Estadístico t (calculado): {t_stat:.3f}")
13 print(f"p-valor: {p_value_right:.5f}")
14
15 # Criterio de decisión usando valor critico
16 if abs(t_critico) < abs(t_stat):
17     print(f"Se rechaza H0 usando el método del valor crítico.")
18 else:
19     print(f"No se rechaza H0 usando el método del valor crítico.")
20
21 # Criterio de decisión usando p-value
22 if p_value_right < alpha:
23     print(f"Se rechaza H0 usando el método del p-valor.")
24 else:
25     print(f"No se rechaza H0 usando el método del p-valor.")

```

```

Estadístico t (valor crítico): 2.391
Estadístico t (calculado): 2.951
p-valor: 0.00227
Se rechaza H0 usando el método del valor crítico.
Se rechaza H0 usando el método del p-valor.

```

 Existe evidencia estadística suficiente para validar la afirmación del analista: el rendimiento en exceso mensual de la acción tecnológica es significativamente superior a cero.

Ejemplo 7:

El departamento de Tesorería de una multinacional evalúa la efectividad de una nueva política de cobranza y descuentos por pago anticipado. El objetivo es verificar si la política causó un cambio significativo en el Plazo Medio de Cobro (*Days Sales Outstanding, DSO*), el cual históricamente se ha mantenido en 45 días.

Dado que un cobro demasiado acelerado podría indicar que los descuentos ofrecidos son excesivamente agresivos (destruyendo margen) y un cobro lento afecta la liquidez, Tesorería realiza una prueba para detectar cualquier desviación significativa (a la baja o al alza) respecto al objetivo. Se analiza una muestra aleatoria de $n = 80$ facturas cobradas bajo el nuevo esquema. Se obtiene un DSO promedio muestral de $\bar{x} = 41.2$ días con una desviación estándar de $s = 14.5$ días.

Plantea las hipótesis nula y alternativa. Usando un nivel de significancia de 5%, ¿qué concluyes?

Formulación de Hipótesis:

$H_0 : \mu = 45$ (La nueva política no altera el DSO; el plazo medio se mantiene en el objetivo de 45 días)

$H_1 : \mu \neq 45$ (La nueva política altera significativamente el DSO, ya sea reduciéndolo o incrementándolo)

Tipo de prueba: Dos colas (bilateral)

Nivel de significancia (α): 0.05 (5%)

```

1 # Datos de la muestra
2 mean_dso = 41.2      # Promedio muestral de días de cobro
3 s = 14.5            # Desviación estándar en días
4 n = 80              # Tamaño muestral (facturas)
5 mu_0 = 45.0         # Meta histórica de días de cobro
6 alpha = 0.05        # Nivel de significancia
7
8 t_critico = stats.t.ppf(alpha/2, df=n-1)
9 t_stat = (mean_dso - mu_0) / (s / np.sqrt(n)) # Estadístico t de una muestra
10 p_value = 2 * (1 - stats.t.cdf(abs(t_stat), df=n-1)) # p-valor para prueba de dos colas
11
12 print(f"Estadístico t (valor crítico): {t_critico:.3f}")
13 print(f"Estadístico t (calculado): {t_stat:.3f}")
14 print(f"p-valor: {p_value:.5f}")
15
16 # Criterio de decisión usando valor critico
17 if abs(t_critico) < abs(t_stat):
18     print(f"Se rechaza H0 usando el método del valor crítico.")
19 else:
20     print(f"No se rechaza H0 usando el método del valor crítico.")
21
22 # Criterio de decisión usando p-value
23 if p_value < alpha:
24     print(f"Se rechaza H0 usando el método del p-valor.")
25 else:
26     print(f"No se rechaza H0 usando el método del p-valor.")

```

Estadístico t (valor crítico): -1.990

Estadístico t (calculado): -2.344

p-valor: 0.02159

Se rechaza H0 usando el método del valor crítico.

Se rechaza H0 usando el método del p-valor.

Dado que en este caso tenemos un test de dos colas también puede usar el método del intervalo de confianza para realizar una prueba de hipótesis:

```
1 # Método 1
2 ic_inferior, ic_superior = stats.t.interval(0.95, df=n-1, loc=mean_dso, scale=s/np.sqrt(n))
3 print(f"IC 95%: [{ic_inferior:.2f}, {ic_superior:.2f}]")
```

IC 95%: [37.97, 44.43]

```
1 # Método 2
2 limite_inferior = mean_dso - abs(t_critico)*s/np.sqrt(n)
3 limite_superior = mean_dso + abs(t_critico)*s/np.sqrt(n)
4
5 print(f"Límite inferior: {limite_inferior:.2f}")
6 print(f"Límite superior: {limite_superior:.2f}")
```

Límite inferior: 37.97

Límite superior: 44.43

Dado que el IC no contiene a 45, se rechaza H_0

 Existe evidencia estadística suficiente para concluir que la nueva política de cobranza causó un cambio significativo en el *plazo medio de cobro (DSO)*.

¿La nueva política logró reducir significativamente el DSO?

Se requiere reformular la prueba de hipótesis:

$H_0 : \mu \geq 45$ (La política no redujo el DSO respecto al promedio histórico)

$H_1 : \mu < 45$ (La política redujo significativamente el DSO por debajo de 45 días)

Tipo de prueba: Cola inferior (unilateral)

```

1 t_critico_left = stats.t.ppf(alpha, df=n-1)
2 p_value_left = stats.t.cdf(t_stat, df=n-1) # p-valor para prueba de cola inferior
3
4 print(f"Estadístico t (valor crítico): {t_critico_left:.3f}")
5 print(f"Estadístico t (calculado): {t_stat:.3f}")
6 print(f"p-valor:          {p_value_left:.5f}")
7
8 # Criterio de decisión usando valor critico
9 if abs(t_critico_left) < abs(t_stat):
10     print(f"Se rechaza H0 usando el método del valor crítico.")
11 else:
12     print(f"No se rechaza H0 usando el método del valor crítico.")
13
14 # Criterio de decisión usando p-value
15 if p_value_left < alpha:
16     print(f"Se rechaza H0 usando el método del p-valor.")
17 else:
18     print(f"No se rechaza H0 usando el método del p-valor.")

```

Estadístico t (valor crítico): -1.664

Estadístico t (calculado): -2.344

p-valor: 0.01080

Se rechaza H0 usando el método del valor crítico.

Se rechaza H0 usando el método del p-valor.

Resumen para elegir la cola correcta:

- *Usa cola izquierda ($\mu < \mu_0$):* Si únicamente te interesa demostrar la efectividad en reducir la variable (ej. reducir costos, reducir días de cobro, reducir tasa de morosidad).
- *Usa dos colas ($\mu \neq \mu_0$):* Si te interesa auditar estabilidad o detectar desviaciones en cualquier dirección porque un cambio hacia arriba o hacia abajo implica decisiones operativas distintas.