

Fundamentos de Analítica de Datos Financieros

Parte I | Econometría Financiera

Víctor Macías E.

En estas notas se usarán las siguientes librerías de Python:

```
1 import numpy as np
2 import pandas as pd
3 import scipy.stats as stats
4 import matplotlib.pyplot as plt
5 import seaborn as sns
```

Estadística Descriptiva e Inferencial

Estadística Descriptiva

Métodos y herramientas orientados a *organizar, resumir y presentar* datos cuantitativos para extraer valor de negocio inmediato.

Estadística Inferencial

Métodos probabilísticos utilizados para *hacer deducciones, proyecciones y estimaciones* sobre una población a partir del análisis de una muestra representativa.

Los Datos en el Entorno Financiero

Los datos son números en contexto. Sin el contexto del negocio, son solo ruido.

El acceso a fuentes alternativas —como imágenes satelitales, audios de earnings calls, tráfico web o transacciones de tarjetas— se ha vuelto imprescindible en el análisis financiero moderno. Sin embargo, su valor no radica en su volumen, sino en la capacidad de interpretarlos dentro del contexto del negocio.

Aplicación Financiera: Datos Satelitales

El uso de datos satelitales recolectados en tiempo real permite:

- *Evaluación de riesgo ESG y climático:* Monitoreo de activos físicos frente a eventos extremos.
- *Proyección de ventas en retail:* Estimación del volumen de clientes en estacionamientos comerciales antes de la publicación de resultados trimestrales.
- *Seguimiento de cadenas de suministro:* Medición del tráfico de buques de carga en puertos clave.

Aplicación: LendingClub

Los primeros 8 préstamos de un total de 50 incluidos en `loan50` de **LendingClub** (plataforma de préstamos P2P) son:

```
1 loan50 = pd.read_csv("datos/loan50.csv")
2
3 vars_interes = ['loan_amount', 'interest_rate', 'term', 'grade', 'state', 'total_income', 'homeownership']
4 loan50[vars_interes].head(8)
```

	loan_amount	interest_rate	term	grade	state	total_income	homeownership
0	22000	10.90	60	B	NJ	59000	rent
1	6000	9.92	36	B	CA	60000	rent
2	25000	26.30	36	E	SC	75000	mortgage
3	6000	9.92	36	B	CA	75000	rent
4	25000	9.43	60	B	OH	254000	mortgage
5	6400	9.92	36	B	IN	67000	mortgage
6	3000	17.09	36	D	NY	28800	rent
7	14500	6.08	36	A	MO	80000	mortgage

Importancia del Contexto Financiero

Entender cada variable es clave para evitar modelos sesgados.

	Variable	Descripción
0	loan_amount	Monto desembolsado del préstamo (USD)
1	interest_rate	Tasa de interés pactada (% anual)
2	term	Plazo del crédito (meses)
3	grade	Calificación de riesgo interno (A a G)
4	state	Estado de residencia del prestatario (EE.UU.)
5	total_income	Ingreso anual bruto verificado (USD)
6	homeownership	Vivienda (Propia, Hipotecada, Arriendo)

Clasificación de Variables

Una variable representa un atributo o característica observable y puede ser:

1. Numéricas (Cuantitativas)
2. Categóricas (Cualitativas)

1. Numéricas (Cuantitativas)

Toman valores numéricos donde las operaciones aritméticas (sumas, promedios, ratios) tienen un significado real.

Note

Un código de cuenta bancaria o número de tarjeta es una variable categórica, aunque esté compuesto por dígitos.

2. Categóricas (Cualitativas)

Clasifican las observaciones en grupos o categorías disjuntas.

Variables numéricas

Discretas

Toman un número finito o contable de valores enteros. Por ejemplo, número de tarjetas de crédito activas, número de impagos en el histórico del cliente.

Continuas

Toman un número infinito de valores posibles dentro de un intervalo. Por ejemplo, tasa de interés, retorno diario de una acción, valor presente neto (VPN).

Variables categóricas

Nominales

Las categorías no poseen un orden explícito ni jerarquía. Por ejemplo, sexo, comuna de residencia, sector de actividad económica.

Ordinales

Las categorías tienen una jerarquía o escala lógica intrínseca. Por ejemplo, calificación crediticia (grade: $A > B > C \dots$), rating de riesgo soberano (AAA a D), tamaño de empresa (micro, pequeña, mediana y grande).

Identificación de tipos de datos

```
1 loan50[vars_interes].dtypes.to_frame(name='tipo de dato')
```

	tipo de dato
loan_amount	int64
interest_rate	float64
term	int64
grade	str
state	str
total_income	int64
homeownership	str

Distribución de los Datos

La distribución es el patrón de variación de una variable o un conjunto de éstas.

El tipo de variable (numérica o categórica) condiciona el método de análisis de la distribución.

Variables Numéricas

- Medidas de tendencia central y localización
- Medidas de dispersión
- Medidas de forma de distribución
- Medidas de asociación entre variables

Variables Categóricas

- Tablas de frecuencia absoluta/relativa y proporciones

Medidas de tendencia central y localización

- Media aritmética
- Mediana
- Media geométrica
- Moda
- Percentiles y Cuartiles

Media Aritmética

$$\bar{x} = \frac{\sum_{i=1}^n x_i}{n}$$

```
1 media_tasa = loan50['interest_rate'].mean()  
2 print(f"Tasa promedio de la cartera: {media_tasa:.2f}%")
```

Tasa promedio de la cartera: 11.57%

! Sensibilidad a outliers

Un solo crédito en default severo o una transacción atípica puede distorsionar gravemente la media aritmética.

💡 Suponga que la variable `default` toma valor 1 si la empresa quebró y 0 si se mantuvo solvente. Si la media de `default` es 0.045, entonces el 4.5% de las empresas en la muestra quebró.

Mediana

La mediana (P_{50}) es el punto central de un conjunto de datos ordenados. Divide la distribución en dos partes iguales (50% por encima y 50% por debajo).

```
1 mediana_tasa = loan50['interest_rate'].median()  
2 print(f"Mediana de la tasa de interés: {mediana_tasa:.2f}%")
```

Mediana de la tasa de interés: 9.93%

Note

A diferencia de la media, la mediana es menos sensible a valores extremos (outliers).

Media Geométrica

$$\overline{x}_g = \sqrt[n]{x_1 \times x_2 \times \cdots \times x_n} = \left(\prod_{i=1}^n x_i \right)^{\frac{1}{n}}$$

Ejemplo 1:

Un fondo de inversión reporta un retorno del -20% en el Año 1 y del $+20\%$ en el Año 2. ¿Cuál es el rendimiento anual del portafolio?

```
1 retorno = np.array([-0.20, 0.20])
2
3 media_aritmetica = retorno.mean()
4 media_geometrica = np.prod(1 + retorno)**(1/len(retorno)) - 1
5
6 print(f"Media Aritmética: {media_aritmetica:.2%}")
7 print(f"Media Geométrica (CAGR): {media_geometrica:.2%}")
```

Media Aritmética: 0.00%

Media Geométrica (CAGR): -2.02%

Si invertiste \$100, al final del año 2 tienes $100 \times 0.8 \times 1.2 = \96 . La media aritmética (0%) engaña; la media geométrica (-2.02%) refleja la pérdida real de capital: $\$100 \times (1 - 0.0202)^2 = \96 .

Moda

El valor con mayor frecuencia en la muestra.

Un conjunto de datos puede tener una moda (unimodal), dos modas (bimodal) o múltiples modas (multimodal) o no tener ninguna.

Percentiles

Representan el valor por debajo del cual se encuentra el $p\%$ de la muestra.

Q_1 : Percentil 25 o primer cuartil.

Q_2 : Percentil 50, mediana o segundo cuartil.

Q_3 : Percentil 75 o tercer cuartil.

Medidas de dispersión

- Rango
- Rango Intercuartílico (IQR)
- Varianza
- Desviación Estándar
- Coeficiente de Variación (CV)

Rango

$$\text{Rango} = \text{Valor Mximo} - \text{Valor Mnimo}$$

Muy sensible a valores extremos en los datos.

Rango Inter cuartílico (IQR)

$$\text{IQR} = Q_3 - Q_1$$

Mide la dispersión del 50% central de los datos. Descarta colas extremas.

Desviación Estándar

La desviación estándar de un conjunto de valores muestrales, expresada por s , es una medida de cuánto se desvían los valores de la media. Mientras mayor es la desviación estándar, mayor es la variabilidad de los datos.

$$s = \sqrt{\frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n - 1}}$$

```
1 desv_est = loan50['interest_rate'].std()  
2 print(f"Desviación estándar de la tasa de interés: {desv_est:.2f}%")
```

Desviación estándar de la tasa de interés: 5.05%

Las unidades de la desviación estándar s son las mismas que las unidades de los valores de datos originales.

Es una de las medidas de variación más usadas. Sin embargo, debe considerarse que se ve afectada por valores extremos.

Varianza

$$s^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n - 1}$$

```
1 varianza = loan50['interest_rate'].var()  
2 print(f"Varianza de la tasa de interés: {varianza:.2f}%")
```

Varianza de la tasa de interés: 25.52%

Coeficiente de Variación (CV)

Normaliza la desviación estándar en relación a la media para comparar variables que tienen desviaciones estándar y medias distintas:

$$CV = \left(\frac{s}{\bar{x}} \right) \times 100\%$$

```
1 cv_tasa = (loan50['interest_rate'].std() / loan50['interest_rate'].mean()) * 100
2 print(f"Coeficiente de Variación de la tasa de interés: {cv_tasa:.2f}%")
```

Coeficiente de Variación de la tasa de interés: 43.68%

Resumen

```
1 resumen_tasa = loan50['interest_rate'].agg(  
2     Observaciones='count',  
3     Media='mean',  
4     Desv_Estandar='std',  
5     Minimo='min',  
6     Q1=lambda x: x.quantile(0.25),  
7     Mediana='median',  
8     Q3=lambda x: x.quantile(0.75),  
9     Maximo='max'  
10 ).to_frame(name='Tasa de Interés (%)')  
11 resumen_tasa.round(2)
```


Tasa de Interés (%)	
Observaciones	50.00
Media	11.57
Desv_Estandar	5.05
Minimo	5.31
Q1	7.96
Mediana	9.93
Q3	13.72
Maximo	26.30

Forma de la Distribución

- Sesgo
- Curtosis

Un histograma de la variable **tasa de interés** nos ayudará a explorar la forma de la distribución de esta variable:

```
1 fig, ax = plt.subplots(figsize=(8, 3.5))
2 sns.histplot(
3     data=loan50['interest_rate'],
4     binwidth=2.5, # Ancho de cada bin
5     binrange=(5, 27.5), # Límite inferior del primero y superior del último
6     color='#2b5c8f',
7     ax=ax,
8 )
9 ax.set_title('Distribución de tasas de interés en préstamos', fontsize=12)
10 ax.set_xlabel('Tasa de Interés (%)')
11 ax.set_ylabel('Número de préstamos')
12 plt.tight_layout()
13 plt.show()
```



Sesgo (skewness)

Mide la falta de simetría o sesgo de una distribución. La asimetría no tiene unidades y no varía al cambiar las unidades de medición de la variable aleatoria.

$$\text{Sesgo} = \frac{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^3}{s^3}$$

- *Distribución Simétrica*: $\text{Media} = \text{Mediana} \Rightarrow \text{Sesgo} = 0$
- *Sesgo Positivo (derecha)*: $\text{Media} > \text{Mediana}$. Típico en tasas de interés, montos de crédito e ingresos (pocas observaciones con valores muy altos).
- *Sesgo Negativo (izquierda)*: $\text{Media} < \text{Mediana}$. Común en precios de activos durante periodos de crash.

Curtosis

Mide el grosor de las colas en la distribución.

$$curtosis = \frac{\frac{\sum_{i=1}^n (x_i - \bar{x})^4}{n}}{\left[\frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n} \right]^2}$$

La curtosis de una variable aleatoria que se distribuye normalmente es 3.

- *Leptocúrtica*: si la curtosis es mayor que 3
- *Platicúrtica*: si la curtosis es menor que 3
- *Mesocúrtica*: si la curtosis es igual a 3

La curtosis no tiene unidades y no varía al cambiar las unidades de medición de la variable aleatoria.

El sesgo y curtosis de la variable **tasa de interés** es:

```
1 sesgo_val = stats.skew(loan50['interest_rate'])
2
3 curtosis_val = stats.kurtosis(loan50['interest_rate'], fisher = False)
4
5 print(f"Sesgo: {sesgo_val:.2f}")
6 print(f"Curtosis: {curtosis_val:.2f}")
```

Sesgo: 1.10

Curtosis: 3.65

El sesgo es positivo y la curtosis es mayor al de una variable que se distribuye normalmente. La distribución de la **tasa de interés** es sesgada a la derecha.

💡 Las distribuciones con una curtosis mayor a 3 (*leptocúrticas*) concentran mayor probabilidad de pérdidas o retornos extremos de los previstos por una distribución normal.

Análisis de outliers y diagrama de caja

Un valor se considera atípico (outlier) si cae fuera del intervalo:

$$[Q_1 - 1.5 \times \text{IQR}, Q_3 + 1.5 \times \text{IQR}]$$

¿Hay outliers en la distribución de la tasa de interés?


```
1 q1 = loan50['interest_rate'].quantile(0.25) # percentil 25
2 q3 = loan50['interest_rate'].quantile(0.75) # percentil 75
3 iqr = q3 - q1 # rango intercuartil
4
5 limite_inf = q1 - 1.5 * iqr
6 limite_sup = q3 + 1.5 * iqr
7
8 outliers = loan50[(loan50['interest_rate'] < limite_inf) |
9                  (loan50['interest_rate'] > limite_sup)]
10 print(f"Límite superior Tukey: {limite_sup:.2f}%")
11 print(f"Número de outliers detectados: {len(outliers)}")
```

Límite superior Tukey: 22.35%

Número de outliers detectados: 2


El diagrama de caja para la variable **tasa de interés** es:

```
1 fig, ax = plt.subplots(figsize=(8, 3))
2 sns.boxplot(x=loan50['interest_rate'], color='#3fa3ab', ax=ax)
3
4 ax.set_title('Boxplot: Tasas de Interés (LendingClub)')
5 ax.set_xlabel('Tasa de Interés (%)')
6 plt.tight_layout()
7 plt.show()
```



Superponiendo la **tasa de interés** de cada uno de los 50 préstamos, se tiene:

```
1 fig, ax = plt.subplots(figsize=(8, 3))
2 sns.boxplot(x=loan50['interest_rate'], color='#3fa3ab', ax=ax)
3 sns.stripplot(x=loan50['interest_rate'], color='#960012', alpha=0.6,
4              jitter=0.2, ax=ax)
5 ax.set_title('Boxplot + Jitter: Tasas de Interés (LendingClub)')
6 ax.set_xlabel('Tasa de Interés (%)')
7 plt.tight_layout()
8 plt.show()
```



Relación entre variables cuantitativas

- Covarianza (s_{xy})
- Coeficiente de correlación de Pearson (r_{xy})

Covarianza (s_{xy})

Mide la dirección de la asociación lineal entre dos variables numéricas:

$$s_{xy} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{n - 1}$$

Coeficiente de correlación (r_{xy})

Estandariza la covarianza en un rango de $[-1, 1]$:

$$r_{xy} = \frac{s_{xy}}{s_x s_y}$$

¿Cuál es la correlación entre el ingreso y el monto del préstamo?

```
1 cov_val = loan50['total_income'].cov(loan50['loan_amount'])
2 cor_val = loan50['total_income'].corr(loan50['loan_amount'])
3
4 print(f"Covarianza: {cov_val:,.2f}")
5 print(f"Correlación: {cor_val:.2f}")
```


Covarianza: 381,259,156.65

Correlación: 0.54

Existe una asociación lineal positiva moderada ($r = 0.54$).
A mayor ingreso, mayor es el monto del crédito otorgado.

A continuación se muestra el gráfico de dispersión de ambas variables.

```
1 fig, ax = plt.subplots(figsize=(8, 3.5))
2 sns.regplot(data=loan50, x='total_income', y='loan_amount', fit_reg=False,
3             color='#027e88', scatter_kws={'alpha': 0.6}, ax=ax,)
4 ax.set_title(f'Ingreso Total vs. Monto de Préstamo (r = {cor_val:.2f})')
5 ax.set_xlabel('Ingreso Total (USD)')
6 ax.set_ylabel('Monto del Préstamo (USD)')
7 plt.tight_layout()
8 plt.show()
```




Precaución: el cuarteto de Anscombe

	dataset	media_x	var_x	media_y	var_y	correlacion
0	I	9.0	11.0	7.500909	4.127269	0.816421
1	II	9.0	11.0	7.500909	4.127629	0.816237
2	III	9.0	11.0	7.500000	4.122620	0.816287
3	IV	9.0	11.0	7.500909	4.123249	0.816521


💡 La correlación entre las variables x e y en cada uno de los datasets es 0.816. Asimismo, las medias y varianzas de ambas variables son las mismas.

Graphs are essential to good statistical analysis (Anscombe, 1973)

```
1 anscombe = sns.load_dataset("anscombe") # Carga de Anscombe desde seaborn
2 fig, axs = plt.subplots(2, 2, figsize=(8, 4.5), sharex=True, sharey=True)
3 for i, dataset_name in enumerate(['I', 'II', 'III', 'IV']):
4     ax = axs[i//2, i%2]
5     sub_df = anscombe[anscombe['dataset'] == dataset_name]
6     sns.regplot(data=sub_df, x='x', y='y', ax=ax, ci=None, color='#2b5c8f', scatter_kws={'s': 10})
7     ax.set_title(f'Dataset {dataset_name} (r = 0.816)')
8 plt.tight_layout()
9 plt.show()
```



...correlación con el mercado



Correlación no implica Causalidad

Dos variables pueden exhibir un coeficiente de correlación cercano a 1.0 o -1.0 sin que exista relación de causa y efecto.

- Causalidad: Una intervención o cambio directo en X causa un cambio comprobable en Y .
- Factor de confusión: Una tercera variable no observada (Z) puede ser la causa de las variaciones simultáneas en X e Y .

¿La satisfacción laboral aumenta el retorno?

Edmans, A. 2011. “Does the stock market fully value intangibles? Employee satisfaction and equity prices”. Journal of Financial Economics.

“I found that the *100 Best Companies to Work for in America* delivered stock returns that beat their peers by an average of 2.3% to 3.8% per year over a 28-year period. That’s 89% to 184% cumulative”.

“It took me four years to complete this study, to verify the robustness of the results and to rule out alternative explanations...”

(Alex Edmans en “*Grow the Pie*”, 2020)

¿Qué explicaciones alternativas se deben excluir?

- ¿La satisfacción laboral causa un buen rendimiento financiero, o es que a las empresas con altos beneficios y acciones en alza les sobra el dinero para gastar en beneficios e iniciativas para sus empleados?
(*Causalidad inversa*)
- ¿Existen características de las empresas (por ejemplo, tamaño, sector, desempeño pasado, pago de dividendos, etc.) que expliquen el rendimiento superior?

Evidence is not proof. A proof is universal

Investigaciones posteriores del propio Alex Edmans junto con otros autores demostraron que esta relación causal depende del entorno regulatorio:

“The Best Companies don’t outperform in countries with heavily regulated labor markets, such as France and Germany. That makes sense. In those countries, the law already guarantees workers a decent level of wellbeing, for example by providing dismissal protection. When the average enterprise is already treating its colleagues well, a firm that’s right at the top may be investing in employee satisfaction excessively”.

(Alex Edmans en “*Grow the Pie*”, 2020)

Datos Financieros

Datos de Corte Transversal (Cross-Section)

Observaciones de múltiples entidades en un único punto del tiempo (ej. los indicadores financieros de las empresas del S&P 500 al cierre de hoy).

Series de Tiempo (Time Series)

Observaciones de una única entidad a lo largo del tiempo (ej. la tasa de cambio USD/CLP observada diariamente durante 5 años).

Datos de Panel (Longitudinales)

Combinación de ambas dimensiones: múltiples entidades (empresas, países, etc.) seguidas a través del tiempo.

¿De dónde provienen los datos?

- Datos observacionales
- Experimentos aleatorizados controlados

Datos observacionales

Son la norma en economía y finanzas. Obtenidos a partir de registros contables, estados financieros o transacciones de mercado donde el investigador no controla la asignación de tratamientos.

Experimentos aleatorizados controlados

Se asignan entidades aleatoriamente a un grupo de *tratamiento* o *control*. Por ejemplo, un banco puede dividir a sus clientes aleatoriamente para evaluar qué estrategia incentiva mejor el ahorro:

Grupo A (Control - Sin mensaje): No recibe ningún mensaje.

Grupo B (Tratamiento - Recordatorio neutro): “Recuerda ahorrar este mes.”

Grupo C (Tratamiento - Aversión a la pérdida): “Estás perdiendo \$50 en intereses por no mover tu dinero a la cuenta de ahorro.”

Así se mide si los mensajes realmente incrementan los depósitos frente a la conducta habitual sin intervención.