

Relación entre la distancia y los precios de los hoteles en Viena

Víctor Macías

Preguntas:

- *¿Qué hoteles son relativamente baratos y a una corta distancia del centro de Viena?*
- *¿Qué patrón muestra la relación entre precios de los hoteles y la distancia al centro de la ciudad?*
- *¿Es la relación entre precio y distancia estable en distintas poblaciones? (por ejemplo, hoteles versus departamentos, distintas ciudades)*
- *¿Cambia la relación (signo y magnitud) entre precio y distancia al añadir otras variables? (por ejemplo, rating)*
- *¿Cuál es el efecto de la calidad del hotel sobre los precios? ¿Cómo afecta el error de medición?*

Se partirá el análisis graficando la relación entre los precios y distancia al centro de la ciudad de los hoteles en Viena (ver Figuras 1 y 2).

Nota que los hoteles ubicados más lejos del centro de la ciudad tienen, en promedio, precios más bajos. Sin embargo, existe una gran dispersión de precios para una distancia determinada al centro de la ciudad.

Asimismo, una comparación entre ambas figuras, permite concluir que una función lineal no captura adecuadamente la relación entre los precios y la distancia al centro de la ciudad.

Por otra parte, la Figura 2 destaca a un conjunto de cinco hoteles que se encuentran a una milla aproximadamente del centro de la ciudad que son relativamente baratos para hospedarse. ¿Cuáles son estos hoteles?

Figura 1





Figura 2



En particular, si comparamos dos hoteles, uno de los cuales está una milla más alejado del centro de la ciudad que el otro, ¿qué diferencia de precio deberíamos esperar entre los dos? Para responder a esta pregunta, se estimará el siguiente modelo:

$$price_i = \alpha_0 + \alpha_1 distance_i + u_i \quad (1)$$

donde *price* es el precio del hotel y *distance* es la distancia del hotel al centro de la ciudad. Se espera que $\alpha_1 < 0$.

La siguiente tabla presenta los resultados de la estimación por MCO:

<i>Dependent variable:</i>	
	price
distance	-14.406*** (2.331)
Constant	132.017*** (4.474)
Observations	207
R ²	0.157
Adjusted R ²	0.153
Residual Std. Error	38.858 (df = 205)
F Statistic	38.199*** (df = 1; 205)

Note: *p<0.1; **p<0.05; ***p<0.01

De acuerdo a estos resultados, los hoteles que están a una milla más alejados del centro de la ciudad son, en promedio, 14 dólares más baratos.

Sin embargo, este modelo no es una buena representación de los datos, porque éstos muestran que la misma diferencia de distancia se asocia con diferencias de precio más grandes cerca del centro de la ciudad. Por lo tanto, la verdadera relación es no lineal.

En lugar de enfocarnos en diferencias absolutas en precios, el análisis se centrará en diferencias relativas, por lo que se estimará el siguiente modelo:

$$\log(price_i) = \beta_0 + \beta_1 distance_i + v_i \quad (2)$$

La siguiente tabla permite una comparación de los resultados de la estimación de los modelos (1) y (2):

	<i>Dependent variable:</i>	
	price	log(price)
	(1)	(2)
distance	-14.406*** (2.331)	-0.131*** (0.018)
Constant	132.017*** (4.474)	4.841*** (0.035)
Observations	207	207
R ²	0.157	0.205
Adjusted R ²	0.153	0.201
Residual Std. Error (df = 205)	38.858	0.301
F Statistic (df = 1; 205)	38.199***	52.895***

Note: *p<0.1; **p<0.05; ***p<0.01

De acuerdo al modelo (2), los hoteles que están una milla más alejados del centro de la ciudad son, en promedio, 13 por ciento más baratos.

Como se señaló anteriormente, el modelo lineal no captura la no linealidad presente en la relación entre precio y distancia al centro de la ciudad. A continuación se estimará el siguiente modelo que considera un cambio de pendiente cuando la distancia es mayor a 2 millas:

$$\log(\text{price}_i) = \gamma_0 + \gamma_1 \text{distance}_i + \gamma_2 d_i(\text{distance}_i - 2) + w_i \quad (3)$$

donde d es una variable dummy que es igual a 1 si $\text{distance} > 2$ y 0, si $\text{distance} \leq 2$.

Nota que:

- Si $\text{distance} \leq 2$, entonces la pendiente es γ_1
- Si $\text{distance} > 2$, entonces la pendiente es $\gamma_1 + \gamma_2$

Nota que la siguiente tabla muestra los valores $\hat{\gamma}_0$, $\hat{\gamma}_1$ y $\hat{\gamma}_1 + \hat{\gamma}_2$:

	<i>Dependent variable:</i>
	log(price)
Distancia menor o igual a 2 millas	-0.309*** (0.035)
Distancia mayor a 2 millas	0.024 (0.032)
Constant	5.015*** (0.044)
Observations	207
R ²	0.314
Adjusted R ²	0.308
Residual Std. Error	0.280 (df = 204)
F Statistic	46.786*** (df = 2; 204)
<i>Note:</i> *p<0.1; **p<0.05; ***p<0.01	

Validez externa: Hoteles versus departamentos

Cuando se estima el modelo (3) para departamentos en Viena ¿Se mantiene el patrón de la relación entre precio y distancia?

	<i>Dependent variable:</i>	
	log(price)	
	Hoteles	Departamentos
	(1)	(2)
Distancia menor o igual a 2 millas	-0.309*** (0.035)	-0.255*** (0.069)
Distancia mayor a 2 millas	0.024 (0.032)	0.117* (0.061)
Constant	5.015*** (0.044)	5.153*** (0.091)
Observations	207	92
R ²	0.314	0.134
Adjusted R ²	0.308	0.114
Residual Std. Error	0.280 (df = 204)	0.418 (df = 89)
F Statistic	46.786*** (df = 2; 204)	6.864*** (df = 2; 89)
<i>Note:</i> *p<0.1; **p<0.05; ***p<0.01		

La comparación entre hoteles y departamentos localizados en un radio de 2 millas del centro, una milla más disminuye el precio. Sin embargo, entre los departamentos que se encuentran a más de dos millas del centro de la ciudad, una milla adicional aumenta el precio (nivel de significancia de 10%).

Validez externa: Amsterdam y Barcelona versus Viena

A continuación se estimará el modelo (3) usando datos de hoteles en Amsterdam y Barcelona.

	<i>Dependent variable:</i>		
	Viena (1)	log(price) Amsterdam (2)	Barcelona (3)
Distancia menor o igual a 2 millas	−0.309*** (0.035)	−0.274*** (0.039)	−0.057 (0.035)
Distancia mayor a 2 millas	0.024 (0.032)	0.026 (0.030)	−0.045 (0.069)
Constant	5.015*** (0.044)	5.243*** (0.046)	4.667*** (0.040)
Observations	207	195	249
R ²	0.314	0.236	0.023
Adjusted R ²	0.308	0.228	0.015
Residual Std. Error	0.280 (df = 204)	0.302 (df = 192)	0.288 (df = 246)
F Statistic	46.786*** (df = 2; 204)	29.716*** (df = 2; 192)	2.854* (df = 2; 246)

Note:

*p<0.1; **p<0.05; ***p<0.01

Mientras el patrón observado entre el logaritmo de los precios y la distancia en Viena se mantiene en los hoteles ubicados a una distancia menor de 2 millas del centro de la ciudad en Amsterdam, la distancia parece no tener un efecto en los precios en Barcelona.

La comparación con otras ciudades europeas muestra que los patrones encontrados en Viena no se mantienen en otros lugares. Por lo tanto, la validez externa de los resultados de Viena es débil.

¿Cambia el efecto de la distancia al incluir otras variables?

A continuación se estimará un modelo que añade la variable *rating* (rating promedio de los clientes). La siguiente tabla presenta estadística descriptiva de esta variable:

Nobs	Media	Mínimo	Percentil 25	Percentil 50	Percentil 75	Máximo
207	4.1	2.2	3.9	4.1	4.4	4.8

El modelo que se estimará es el siguiente:

$$\log(\text{price}_i) = \delta_0 + \delta_1 \text{distance}_i + \delta_2 d_i(\text{distance}_i - 2) + \delta_3 \text{rating}_i + z_i \quad (4)$$

La siguiente tabla muestra los resultados de la estimación del modelo (4):

	<i>Dependent variable:</i>
	log(price)
Distancia menor o igual a 2 millas	-0.270*** (0.032)
Distancia mayor a 2 millas	0.045 (0.029)
Rating	0.352*** (0.047)
Constant	3.535*** (0.201)
Observations	207
R ²	0.463
Adjusted R ²	0.455
Residual Std. Error	0.249 (df = 203)
F Statistic	58.358*** (df = 3; 203)
<i>Note:</i> *p<0.1; **p<0.05; ***p<0.01	

¿Qué puedes concluir de estos resultados?

¿Cuál es el efecto de la calidad del hotel sobre los precios?

La variable calidad es una variable latente. Por lo tanto, se deben usar medidas imperfectas que se encuentran disponible en la base de datos. En este caso, se usará como proxy el rating: hoteles con un rating más alto reflejan una evaluación superior de la experiencia de la visita otorgada por los clientes.

El modelo que se estimará es el siguiente:

$$\log(\text{price}_i) = \phi_0 + \phi_1 \text{rating}_i + w_i \quad (5)$$

donde $\hat{\phi}_1 = \frac{\text{cov}(\text{rating}, \log(\text{price}))}{\text{var}(\text{rating})} \quad (5a)$

Sin embargo, estos rating son una medida ruidosa de la calidad de un hotel por dos razones:

- Ratings puede ser influenciados por factores distintos a calidad. Por ejemplo, los ratings pueden ser afectados por el precio y los clientes pueden otorgar ratings más altos a hoteles más baratos de la misma calidad. Esto no es un error de medición clásico.
- El rating es calculado como el promedio de las evaluaciones de los clientes. Por lo tanto, hoteles con un menor número de calificaciones presentarán promedios con “más ruido”, debido a una muestra más pequeña tiene una mayor variación. Este es un tipo de error de medición clásico.

Si el error de medición clásico juega un papel, su impacto debiera ser mayor en los hoteles con pocas calificaciones que en aquéllos con muchas calificaciones. Para evaluar esta posibilidad la muestra de 207 hoteles se divide en tres grupos: menos de 100 calificaciones, 100-200 calificaciones y más de 200 calificaciones.

La siguiente tabla presenta estadística descriptiva del rating promedio para cada uno de estos grupos:

Grupo	Nobs	Media	Desviación estándar	Mínimo	Máximo
100-200 calificaciones	58	4.03	0.39	2.7	4.6
< 100 calificaciones	77	3.93	0.42	2.2	4.5
> 200 calificaciones	72	4.21	0.26	3.4	4.8

Como era de esperar, la desviación estándar de los ratings es mayor mientras menor sea el número de calificaciones.

Si se estima el modelo sin error de medición, se tiene:

$$\log(\text{price}_i) = \phi_0^* + \phi_1^* \text{rating}_i^* + w_i^* \quad (6)$$

donde $\hat{\phi}_1^* = \frac{\text{cov}(\text{rating}^*, \log(\text{price}))}{\text{var}(\text{rating}^*)}$ (6a). El error de medición está representado por ϵ en:

$$\text{rating}_i = \text{rating}_i^* + \epsilon_i \quad (7)$$

donde $\text{cov}(\text{rating}^*, \epsilon) = 0$ y, por lo tanto, $\text{var}(\text{rating}) = \text{var}(\text{rating}^*) + \text{var}(\epsilon)$.

Reemplazando (7) en $\hat{\phi}_1 = \frac{\text{cov}(\text{rating}, \log(\text{price}))}{\text{var}(\text{rating})}$ (5a), se tiene:

$$\hat{\phi}_1 = \frac{\text{cov}(\text{rating}^*, \log(\text{price})) + \text{cov}(\epsilon, \log(\text{price}))}{\text{var}(\text{rating}^*) + \text{var}(\epsilon)} = \frac{\text{cov}(\text{rating}^*, \log(\text{price}))}{\text{var}(\text{rating}^*)} \frac{\text{var}(\text{rating}^*)}{\text{var}(\text{rating}^*) + \text{var}(\epsilon)}$$

Reemplazando $\text{cov}(\epsilon, \log(\text{price})) = 0$ y amplificando la fracción por $\text{var}(\text{rating}^*)$, se tiene:

$$\hat{\phi}_1 = \hat{\phi}_1^* \frac{\text{var}(\text{rating}^*)}{\text{var}(\text{rating}^*) + \text{var}(\epsilon)}$$

Por lo tanto, considerando que $\text{var}(\text{rating}^*) < \text{var}(\text{rating}^*) + \text{var}(\epsilon)$, se tiene

$$\hat{\phi}_1 < \hat{\phi}_1^*$$

Por lo tanto, bajo la presencia de error de medición clásico en el regresor, la pendiente es menor (*sesgo de atenuación*). Esto ocurre porque el error de medición aumenta $var(rating)$.

La siguiente tabla muestra los resultados de la estimación del modelo (5) para los tres grupos:

	Dependent variable:		
	< 100 calificaciones	log(price) 100-200 calificaciones	> 200 calificaciones
	(1)	(2)	(3)
rating	0.354*** (0.072)	0.438*** (0.119)	0.556*** (0.117)
Constant	3.137*** (0.285)	2.913*** (0.482)	2.390*** (0.493)
Observations	77	58	72
R ²	0.244	0.194	0.244
Adjusted R ²	0.234	0.180	0.233
Residual Std. Error	0.266 (df = 75)	0.349 (df = 56)	0.260 (df = 70)
F Statistic	24.203*** (df = 1; 75)	13.516*** (df = 1; 56)	22.604*** (df = 1; 70)

Note:

*p<0.1; **p<0.05; ***p<0.01

Como era de esperar, la pendiente es más plana en el grupo con menos de 100 calificaciones. Esto puede también visualizarse en la Figura 3.

Figura 3

