

# **Modelos de variable dependiente limitada**

Econometría Financiera

Víctor Macías E.

A continuación se analizarán los siguientes modelos:

- Probabilidad lineal
- Logit
- Probit

# Modelo de probabilidad lineal (MPL)

Estima por MCO un modelo de regresión lineal donde la variable dependiente es binaria ( $Y=1$  o  $Y=0$ ).

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_k X_k + u$$

Los problemas que tiene el uso del MPL son:

- Errores heterocedásticos
- Predicciones de probabilidad negativas o mayores a 1.

# Modelos logit y probit

Los modelos probit y logit son *modelos no lineales* que se utilizan cuando  $Y$  es binaria.

*A diferencia del modelo de probabilidad lineal, los modelos probit y logit aseguran que la probabilidad estimada que  $Y = 1$  se encuentre entre 0 y 1.*

# Modelo Probit

El modelo probit poblacional con regresores  $X_1, X_2, \dots, X_k$  y variable dependiente binaria  $Y$  es:

$$Pr(Y = 1|X_1, X_2, \dots, X_k) = \Phi(\beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_k X_k)$$


donde  $\Phi$  es la función de distribución normal estándar acumulada.

# Modelo Logit

El modelo logit poblacional con regresores  $X_1, X_2, \dots, X_k$  y variable dependiente binaria  $Y$  es:

$$\begin{aligned} Pr(Y = 1 | X_1, X_2, \dots, X_k) &= \frac{1}{1 + e^{-(\beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_k X_k)}} \\ &= \frac{e^{(\beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_k X_k)}}{1 + e^{(\beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_k X_k)}} \end{aligned}$$

En este caso, esta es la función de distribución acumulada de una variable aleatoria logística.



# Efectos marginales

Si  $X_j$  es una variable continua, entonces el efecto de una variación en  $X_j$  es:

$$\frac{\partial \Pr(Y|X_1, X_2, \dots, X_k)}{\partial X_j} = \hat{\beta}_j g(\hat{\beta}_0 + \hat{\beta}_1 X_1 + \hat{\beta}_2 X_2 + \dots + \hat{\beta}_k X_k)$$

donde  $g()$  es la función de densidad de la distribución normal en el caso del modelo probit y la función de densidad de una distribución logística en el modelo logit.

Los efectos marginales dependen de los valores específicos de  $X_1, \dots, X_k$ .

# Agregación de efectos marginales

Dos maneras de agregar los efectos marginales son:

- Calcular el efecto marginal en el promedio de  $X_1, \dots, X_k$  (*Partial effects at the average, PEA*):

$$PEA = \hat{\beta}_j g(\hat{\beta}_0 + \hat{\beta}_1 \bar{X}_1 + \hat{\beta}_2 \bar{X}_2 + \dots + \hat{\beta}_k \bar{X}_k)$$

- Calcular el promedio de los efectos marginales (*Average partial effects, APE*):

$$APE = \frac{1}{n} \sum_{i=1}^n \hat{\beta}_j g(\hat{\beta}_0 + \hat{\beta}_1 X_{1i} + \hat{\beta}_2 X_{2i} + \dots + \hat{\beta}_k X_{ki})$$

Si  $X_j$  es una variable binaria, entonces el efecto de un cambio de  $X_j = 0$  a  $X_j = 1$  sobre la probabilidad que  $Y = 1$  es:

$$Pr(Y = 1|X_j = 1) - Pr(Y = 1|X_j = 0)$$

# ¿Cómo se calculan los coeficientes del modelo?

Los coeficientes de los modelos probit y logit se calculan mediante el **método de máxima verosimilitud** que da lugar a estimadores eficientes (con varianza mínima).

*Nota: La **función de verosimilitud** es la distribución de probabilidad conjunta de los datos, considerada como una función de los coeficientes desconocidos. El estimador de máxima verosimilitud elige los valores de los parámetros que maximizan la probabilidad de haber obtenido los datos que realmente se observan.*

## Medida de ajuste: Pseudo- $R^2$

$$\text{pseudo-}R^2 = 1 - \frac{\ln \mathcal{L}_{\text{modelo}}}{\ln \mathcal{L}_0}$$

$\ln \mathcal{L}_{\text{modelo}}$  (log-likelihood del modelo completo): Mide el ajuste del modelo con todas las variables. Al ser logaritmos de probabilidades ( $< 1$ ), estos valores son negativos. Cuanto más cercano a 0, mejor es el modelo.


$\ln \mathcal{L}_0$  (log-Likelihood del modelo restringido): Mide el ajuste de un modelo que solo incluye el intercepto.


- Si las variables no aportan información  $\ln \mathcal{L}_{modelo} \approx \ln \mathcal{L}_0$  y, por lo tanto,  $\text{pseudo-}R^2 = 0$
- Si las variables logran una predicción perfecta (probabilidades predichas iguales a 1 cuando  $Y = 1$  e iguales a 0 cuando  $Y = 0$ ), entonces  $\ln \mathcal{L}_{modelo} = 0$  y  $\text{pseudo-}R^2 = 1$ .

*En términos generales, no existe gran diferencia en los efectos marginales que producen los modelos logit y probit. Dado que en muchos casos sólo interesan los efectos marginales ( $PEA$  y  $APE$ ) y éstos a menudo son similares entre los modelos de probabilidad lineal, probit y logit, se prefiere el uso del modelo de probabilidad lineal dada la mayor facilidad de interpretación de los coeficientes. Sin embargo, se debe justificar que éste es el caso.*

# Aplicación: Estimando la probabilidad de default

- 10000 clientes
- % de default: 3.3% (333 personas)





**Modelo de probabilidad lineal:**  $P(default = 1|balance) = \beta_0 + \beta_1 balance + \epsilon$

| OLS Regression Results |                  |          |                     |            |        |        |
|------------------------|------------------|----------|---------------------|------------|--------|--------|
| =====                  |                  |          |                     |            |        |        |
| Dep. Variable:         | no_pago          |          | R-squared:          | 0.123      |        |        |
| Model:                 | OLS              |          | Adj. R-squared:     | 0.122      |        |        |
| Method:                | Least Squares    |          | F-statistic:        | 397.7      |        |        |
| Date:                  | Fri, 02 Oct 2026 |          | Prob (F-statistic): | 8.28e-87   |        |        |
| Time:                  | 11:08:45         |          | Log-Likelihood:     | 3644.8     |        |        |
| No. Observations:      | 10000            |          | AIC:                | -7286.     |        |        |
| Df Residuals:          | 9998             |          | BIC:                | -7271.     |        |        |
| Df Model:              | 1                |          |                     |            |        |        |
| Covariance Type:       | HC1              |          |                     |            |        |        |
| =====                  |                  |          |                     |            |        |        |
|                        | coef             | std err  | z                   | P> z       | [0.025 | 0.975] |
| -----                  |                  |          |                     |            |        |        |
| Intercept              | -0.0752          | 0.004    | -18.657             | 0.000      | -0.083 | -0.067 |
| balance                | 0.0001           | 6.51e-06 | 19.943              | 0.000      | 0.000  | 0.000  |
| =====                  |                  |          |                     |            |        |        |
| Omnibus:               | 8547.967         |          | Durbin-Watson:      | 2.023      |        |        |
| Prob(Omnibus):         | 0.000            |          | Jarque-Bera (JB):   | 180810.806 |        |        |
| Skew:                  | 4.243            |          | Prob(JB):           | 0.00       |        |        |
| Kurtosis:              | 22.025           |          | Cond. No.           | 1.93e+03   |        |        |
| =====                  |                  |          |                     |            |        |        |

Notes:

[1] Standard Errors are heteroscedasticity robust (HC1)

[2] The condition number is large, 1.93e+03. This might indicate that there are strong multicollinearity or other numerical problems.

**Modelo logit:**  $P(default = 1|balance) = \frac{\exp(\beta_0 + \beta_1 \times balance)}{1 + \exp(\beta_0 + \beta_1 \times balance)}$

Optimization terminated successfully.  
 Current function value: 0.079823  
 Iterations 10

| Logit Regression Results |                  |         |                   |       |            |        |
|--------------------------|------------------|---------|-------------------|-------|------------|--------|
| =====                    |                  |         |                   |       |            |        |
| Dep. Variable:           | no_pago          |         | No. Observations: |       | 10000      |        |
| Model:                   | Logit            |         | Df Residuals:     |       | 9998       |        |
| Method:                  | MLE              |         | Df Model:         |       | 1          |        |
| Date:                    | Fri, 02 Oct 2026 |         | Pseudo R-squ.:    |       | 0.4534     |        |
| Time:                    | 11:08:45         |         | Log-Likelihood:   |       | -798.23    |        |
| converged:               | True             |         | LL-Null:          |       | -1460.3    |        |
| Covariance Type:         | nonrobust        |         | LLR p-value:      |       | 6.233e-290 |        |
| =====                    |                  |         |                   |       |            |        |
|                          | coef             | std err | z                 | P> z  | [0.025     | 0.975] |
| -----                    |                  |         |                   |       |            |        |
| Intercept                | -10.6513         | 0.361   | -29.491           | 0.000 | -11.359    | -9.943 |
| balance                  | 0.0055           | 0.000   | 24.952            | 0.000 | 0.005      | 0.006  |
| =====                    |                  |         |                   |       |            |        |

Possibly complete quasi-separation: A fraction 0.13 of observations can be perfectly predicted. This might indicate that there is complete quasi-separation. In this case some parameters will not be identified.

**Modelo probit:**  $P(\text{default} = 1|\text{balance}) = \Phi(\beta_0 + \beta_1 \times \text{balance})$

Optimization terminated successfully.  
Current function value: 0.080276  
Iterations 9

| Probit Regression Results |                  |         |                   |       |            |        |
|---------------------------|------------------|---------|-------------------|-------|------------|--------|
| =====                     |                  |         |                   |       |            |        |
| Dep. Variable:            | no_pago          |         | No. Observations: |       | 10000      |        |
| Model:                    | Probit           |         | Df Residuals:     |       | 9998       |        |
| Method:                   | MLE              |         | Df Model:         |       | 1          |        |
| Date:                     | Fri, 02 Oct 2026 |         | Pseudo R-squ.:    |       | 0.4503     |        |
| Time:                     | 11:08:45         |         | Log-Likelihood:   |       | -802.76    |        |
| converged:                | True             |         | LL-Null:          |       | -1460.3    |        |
| Covariance Type:          | nonrobust        |         | LLR p-value:      |       | 5.804e-288 |        |
| =====                     |                  |         |                   |       |            |        |
|                           | coef             | std err | z                 | P> z  | [0.025     | 0.975] |
| -----                     |                  |         |                   |       |            |        |
| Intercept                 | -5.3539          | 0.168   | -31.861           | 0.000 | -5.683     | -5.025 |
| balance                   | 0.0027           | 0.000   | 25.111            | 0.000 | 0.002      | 0.003  |
| =====                     |                  |         |                   |       |            |        |


Possibly complete quasi-separation: A fraction 0.33 of observations can be perfectly predicted. This might indicate that there is complete quasi-separation. In this case some parameters will not be identified.

¡Los coeficientes de los modelos logit y probit no son los efectos marginales!


| Modelo        | <i>PEA</i> | <i>APE</i> |
|---------------|------------|------------|
| <b>MPL</b>    | 0.0001     | 0.0001     |
| <b>Logit</b>  | 0.00001    | 0.0001     |
| <b>Probit</b> | 0.00001    | 0.0001     |

*Nota: Los valores fueron aproximados.*

# ¡El modelo de probabilidad lineal predice probabilidades negativas!



# ¡Probabilidades predichas entre cero y uno!



**Modelo de probabilidad lineal:**

$$P(\text{default} = 1 | \text{balance} = 2000) = -0.07519 + 0.00013 \times 2000 = 0.1848$$

**Modelo logit:**

$$P(\text{default} = 1 | \text{balance} = 2000) = \frac{\exp(-10.65 + 0.0055 \times 2000)}{1 + \exp(-10.65 + 0.0055 \times 2000)} = 0.5866$$

**Modelo probit:**

$$P(\text{default} = 1 | \text{balance} = 2000) = \Phi(-5.35 + 0.0027 \times 2000) = \Phi(0.05) = 0.5199$$

# **Un modelo para predecir la probabilidad de default**

Separar la muestra entre **datos de entrenamiento o training dataset (80%)** y **datos de prueba o test dataset (20%)**.

# Matriz de confusión

| Real \ Predicción | $\hat{Y} = 0$ | $\hat{Y} = 1$ | Total             |
|-------------------|---------------|---------------|-------------------|
| Y = 0             | TN            | FP            | TN + FP           |
| Y = 1             | FN            | TP            | FN + TP           |
| Total             | TN + FN       | FP + TP       | TN + FN + FP + TP |

Cada uno de los elementos de la matriz corresponde al número de observaciones en una categoría determinada.

# ¿Cómo construir la matriz de confusión?

*Paso 1:* Seleccionar umbral  $p_0$ . Usualmente los paquete estadísticos usan  $p_0 = 0.5$ . Al cambiar el valor de  $p_0$  cambia el número de observaciones en cada celda de la matriz.

*Paso 2:* Asignar  $\hat{Y} = 0$  o  $\hat{Y} = 1$

- Si  $\hat{p} \geq p_0$ , entonces  $\hat{Y} = 1$
- Si  $\hat{p} < p_0$ , entonces  $\hat{Y} = 0$

# Métricas construidas a partir de la matriz de confusión

**Accuracy:** Proporción de observaciones correctamente predichas:

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}$$

Nota que en datos desbalanceados (por ejemplo, 99% no default, 1% default), un modelo ingenuo que prediga siempre 0 tendrá 99% de accuracy pero cero valor práctico.

**Sensitivity (TPR, recall):** De todos los casos que realmente son positivos, ¿qué porcentaje logró capturar el modelo? Corresponde a la tasa de verdaderos positivos:

$$\text{Sensitivity} = \frac{TP}{FN + TP}$$

Si el costo de los  $FN$  es alto (por ejemplo, otorgar un crédito de alto monto a un cliente que terminará en default), esta métrica cobra la máxima importancia operacional.

**Specificity (TNR):** De todos los casos que realmente son negativos, ¿qué porcentaje clasificó correctamente el modelo? Corresponde a la tasa de verdaderos negativos:

$$\text{Specificity} = \frac{TN}{TN + FP}$$


**Tasa de falsos positivos:** Responde a la pregunta: ¿Qué proporción de los casos realmente negativos fueron clasificados incorrectamente como positivos?

$$FPR = 1 - \text{specificity} = 1 - \frac{TN}{TN + FP} = \frac{FP}{TN + FP}$$

# Aplicación: Riesgo de crédito

- *Falso positivo:*  $\hat{p} \geq p_0$ , pero `default = 0`. Esto conlleva a que se rechace una solicitud de crédito de alguien que en realidad sí era solvente (negar crédito a un buen cliente).
- *Falso negativo:*  $\hat{p} < p_0$ , pero `default = 1`. Implica aprobar una solicitud de crédito de alguien que no era solvente (dar crédito a alguien que no lo pagará).

# Matriz de confusión con $p_0 = 0.5$



De la matriz de confusión, se tiene:  $TP = 15$ ,  $TN = 1927$ ,  $FP = 6$  y  $FN = 52$ .

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} = \frac{1927 + 15}{2000} = 0.971$$

$$Sensibilidad \text{ (Recall)} = \frac{TP}{TP + FN} = \frac{15}{15 + 52} = 0.2239$$

$$Especificidad = \frac{TN}{TN + FP} = \frac{1927}{1927 + 6} = 0.9969$$

# Matriz de confusión con $p_0 = 0.3$

| Valor observado | No Default | Default |
|-----------------|------------|---------|
|                 | 1905       | 28      |
| Default         | 38         | 29      |

Valor predicho

No Default

Default

De la matriz de confusión, se tiene:  $TP = 29$ ,  $TN = 1905$ ,  $FP = 28$  y  $FN = 38$ .

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} = \frac{29 + 1905}{2000} = 0.967$$

$$Sensibilidad \text{ (Recall)} = \frac{TP}{TP + FN} = \frac{29}{29 + 38} = 0.4328$$

$$Especificidad = \frac{TN}{TN + FP} = \frac{1905}{1905 + 28} = 0.9855$$

# ROC (Receiver Operating Characteristic)

La curva ROC (en naranja) muestra la relación entre la **tasa de verdaderos positivos** (TPR, también conocida como Recall o Sensibilidad) en el eje Y y la **tasa de falsos positivos** (FPR, *1 - specificity*) en el eje X, para diferentes umbrales de decisión.

*Nota:*  $1 - specificity$  mide la proporción de quienes no hicieron default que son incorrecta mente clasificados como `default = Yes`.

# Area under the curve (AUC)

Es una manera de resumir la información de la ROC curve en un único número es el área bajo la curva ROC conocido como AUC.

Generalmente, el AUC tiene un valor entre 0.5 y 1, representando un valor igual a 1 una predicción perfecta.

# Si se disminuye el umbral de clasificación ( $p_0$ )

El modelo se vuelve más permisivo a la hora de clasificar algo como `default` (positivo). Esto significa que más observaciones, tanto las verdaderamente positivas como las verdaderamente negativas, serán clasificadas como positivas.

**Aumenta la TPR:** Al clasificar más casos como `default` (positivos), es más probable que se capture un mayor número de verdaderos positivos. Por lo tanto, la *tasa de verdaderos positivos* (sensibilidad o recall) aumenta.

**Aumenta la FPR:** Al ser más permisivo, el modelo también cometerá más errores al clasificar como positivos a casos que en realidad son negativos (falsos positivos). Por lo tanto, la *tasa de falsos positivos* también aumenta.

## **Si se aumenta el umbral de clasificación ( $p_0$ )**


El modelo se vuelve más estricto, clasificando menos cosas como positivas.

**Disminuye la TPR:** Se detectan menos verdaderos positivos.

**Disminuye la FPR:** También se cometen menos errores de falso positivo.

*A medida que el umbral se mueve desde 1 (muy estricto, pocos positivos predichos, baja TPR y baja FPR) hasta 0 (muy permisivo, muchos positivos predichos, alta TPR y alta FPR), la curva asciende y se desplaza hacia la derecha.*

# Aplicación: Curva ROC y AUC



# AUC

El Área Bajo la Curva (AUC) para este modelo es de 0.95. Un valor de AUC cercano a 1 indica un modelo con una excelente capacidad para distinguir entre `default` (clase positiva) y `no default` (clase negativa), mientras que un AUC de 0.5 sugiere un rendimiento similar al de un clasificador aleatorio. Este modelo tiene un AUC alto, lo que es una buena señal de su poder predictivo.

# ¿Qué valor de $p_0$ elegir?

Los errores no cuestan lo mismo:

- *Falso Negativo (FN)*: Prestarle dinero a alguien que cae en default. Perderás la totalidad del capital prestado (costo muy alto).
- *Falso Positivo (FP)*: Rechazar a un cliente sano. ¡Perderás a un cliente bueno!

La curva ROC permite evaluar cada punto  $(FPR, TPR)$  y calcular la función de costo total de negocio:

$$\text{Costo Total}(p_0) = C_{FN} \times FN(p_0) + C_{FP} \times FP(p_0)$$

donde  $C_{FN}$  es el costo monetario de un falso negativo y  $C_{FP}$  el de un falso positivo. El umbral óptimo será aquel  $p_0$  que minimice la función de costo.