

Regresión lineal múltiple

Parte I | Econometría Financiera

Víctor Macías E.

En la regresión lineal simple intentamos predecir o explicar una variable (Y) usando una sola variable (X). Sin embargo, el mundo real es complejo: el precio de una acción, el retorno de un activo o el PIB no dependen de una sola variable.

La *regresión lineal múltiple* nos permite entender cómo varias variables independientes ($X_1, X_2, \dots, X_k$) influyen simultáneamente sobre una variable dependiente (Y).

La regresión lineal múltiple permite medir el efecto de una variable sobre Y manteniendo todas las demás constantes (ceteris paribus).

Modelo poblacional

$$Y_i = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + \cdots + \beta_k X_{ki} + \epsilon_i$$

donde:

Y_i (variable dependiente): Lo que queremos predecir o explicar (ej. el retorno de una acción).

$X_{1i}, X_{2i}, \dots, X_{ki}$ (variables independientes/regresoras): Los factores explicativos (ej. tasa de interés, inflación, crecimiento del sector).

β_0 (constante): El valor esperado de Y cuando todas las X son iguales a cero.

$\beta_1, \beta_2, \dots, \beta_k$ (coeficientes de regresión): Miden el impacto individual de cada predictor.

ϵ_i (error o perturbación): Recoge todo lo que afecta a Y pero que no está incluido en el modelo (ruido, factores no observables, errores de medición).

Interpretación de los coeficientes

β_j : Representa el cambio promedio esperado en Y ante un incremento de una unidad en X_j , manteniendo constantes todas las demás variables del modelo.

R^2 ajustado ($\bar{R}^2$)

Esta medida de bondad del ajuste penaliza la adición de variables independientes a un modelo.

$$\bar{R}^2 = 1 - \frac{n - 1}{n - k - 1} \times (1 - R^2)$$

donde:

$\bar{R}^2$ es el coeficiente de determinación ajustado.

R^2 es el coeficiente de determinación.

n es el tamaño de la muestra.

k es el número de regresores en el modelo de regresión.

Aplicación: Modelo de factores

$$\underbrace{R_{i,t} - R_{f,t}}_{\text{Exceso de Retorno}} = \alpha_i + \beta_1 \underbrace{(R_{m,t} - R_{f,t})}_{\text{Riesgo de Mercado}} + \beta_2 \underbrace{\text{SMB}_t}_{\text{Tamaño}} + \beta_3 \underbrace{\text{HML}_t}_{\text{Valor}} + \beta_4 \underbrace{\text{MOM}_t}_{\text{Momentum}} + \beta_5 \underbrace{\text{RMW}_t}_{\text{Rentabilidad}} + \beta_6 \underbrace{\text{CMA}_t}_{\text{Inversión}} + \epsilon_{i,t}$$

Prima de riesgo del mercado ($R_{Mt} - R_{Ft}$): El exceso de rentabilidad de la cartera de mercado sobre la tasa libre de riesgo.

Tamaño (SMB - Small Minus Big): La diferencia entre la rentabilidad de una cartera de acciones de baja capitalización y una de alta capitalización.

Valor (HML - High Minus Low): La diferencia entre la rentabilidad de acciones con un alto valor en libros frente a valor de mercado (acciones de valor) y acciones con un bajo valor en libros frente a mercado (acciones de crecimiento).

Rentabilidad (RMW - Robust Minus Weak): El diferencial de rendimiento entre acciones con una rentabilidad operativa alta (*robust*) y una rentabilidad operativa baja (*weak*).

Inversión (CMA - Conservative Minus Aggressive): El diferencial de rendimiento entre las acciones de empresas que invierten de manera conservadora (bajo crecimiento de activos) y aquellas que invierten de forma agresiva (alto crecimiento de activos).

Momentum (MOM): La diferencia de rentabilidad entre una cartera de acciones con rendimiento reciente positivo y una con rendimiento reciente negativo.

Acciones: Nvidia y Exxon Mobil

Período: Enero 2015 - Junio 2026

Frecuencia: Mensual

R_i es el retorno mensual calculado a partir de los precios de cierre ajustados de *NVDA* y *XOM* obtenidos desde Yahoo Finance.

El resto de las variables fue obtenida desde la página web de Kenneth French ([link](#)).

Nota: R_f es la tasa libre de riesgo de bonos del Tesoro de Estados Unidos a un mes.

A continuación se presentan observaciones para las distintas variables explicativas que se incluirán en el modelo de regresión lineal múltiple:

	Mkt_RF	SMB	HML	MOM	RMW	CMA	RF
Date							
2025-09	3.39	-2.24	-0.93	4.71	-2.15	-2.24	0.33
2025-10	1.96	-1.62	-2.76	0.19	-5.80	-4.04	0.37
2025-11	-0.13	1.62	3.62	-1.71	1.66	0.62	0.30
2025-12	-0.36	-0.17	2.36	-2.34	0.38	0.39	0.34
2026-01	1.03	3.21	3.82	4.89	1.80	1.81	0.30
2026-02	-1.18	0.74	2.71	1.32	1.91	5.04	0.28
2026-03	-5.18	0.66	3.41	1.57	-2.08	-0.10	0.29
2026-04	9.95	0.38	-1.17	9.52	-4.30	-3.78	0.29
2026-05	4.91	-2.77	-2.16	1.38	-8.42	-1.40	0.31
2026-06	-1.07	4.58	3.34	4.76	-4.64	3.46	0.29

Estadística descriptiva

	Mín	P25	Mediana	Media	P75	Máx	Desv. Est.
Mkt_RF	-13.35	-1.45	1.28	1.01	3.41	13.58	4.50
SMB	-8.18	-2.10	-0.21	-0.15	1.32	8.33	2.93
HML	-13.83	-2.15	-0.46	-0.03	2.12	12.86	3.69
MOM	-16.21	-2.22	0.52	0.35	2.93	10.00	3.98
RMW	-8.42	-1.48	0.34	0.14	1.51	7.19	2.31
CMA	-7.08	-1.63	-0.41	-0.07	1.29	7.73	2.40
RF	0.00	0.01	0.12	0.16	0.33	0.48	0.16

Resultados de estimaciones por MCO para NVDA, 2015-2026

	Y				
	(1)	(2)	(3)	(4)	(5)
Mkt_RF	1.703*** (0.204)	1.733*** (0.203)	1.711*** (0.212)	1.645*** (0.209)	1.643*** (0.216)
SMB		-0.262 (0.332)	-0.293 (0.343)	-0.194 (0.358)	-0.198 (0.373)
HML		-0.896*** (0.254)	-0.919*** (0.261)	-0.656* (0.334)	-0.659* (0.343)
MOM			-0.098 (0.250)		-0.009 (0.256)
RMW				0.415 (0.410)	0.412 (0.420)
CMA				-0.727 (0.491)	-0.725 (0.498)
Intercept	3.435*** (0.939)	3.358*** (0.896)	3.408*** (0.908)	3.362*** (0.893)	3.366*** (0.906)
Adj. R2	0.3360	0.4049	0.4011	0.4090	0.4044
Observations	137	137	137	137	137
R ²	0.341	0.418	0.419	0.431	0.431

Significance levels: * p < 0.1, ** p < 0.05, *** p < 0.01. Format of coefficient cell: Coefficient (Std. Error)

Resultados de estimaciones por MCO para XOM, 2015-2026

	Y				
	(1)	(2)	(3)	(4)	(5)
Mkt_RF	0.743*** (0.134)	0.752*** (0.116)	0.711*** (0.120)	0.801*** (0.118)	0.764*** (0.121)
SMB		0.069 (0.190)	0.013 (0.194)	0.204 (0.202)	0.127 (0.209)
HML		1.078*** (0.145)	1.037*** (0.148)	0.779*** (0.188)	0.724*** (0.192)
MOM			-0.180 (0.142)		-0.195 (0.143)
RMW				0.257 (0.231)	0.193 (0.235)
CMA				0.580** (0.277)	0.633** (0.279)
Intercept	0.041 (0.617)	0.050 (0.512)	0.141 (0.515)	0.018 (0.504)	0.119 (0.508)
Adj. R2	0.1794	0.4454	0.4479	0.4624	0.4659
Observations	137	137	137	137	137
R ²	0.185	0.458	0.464	0.482	0.489

Significance levels: * p < 0.1, ** p < 0.05, *** p < 0.01. Format of coefficient cell: Coefficient (Std. Error)

Cálculo del $\bar{R}^2$

$$\bar{R}^2 = 1 - \frac{n - 1}{n - k - 1} \times (1 - R^2)$$

NVDA:

$$\bar{R}^2 = 1 - \frac{137-1}{137-6-1} \times (1 - 0.431) = 1 - \frac{136}{130} \times 0.569 = 0.40$$

XOM:

$$\bar{R}^2 = 1 - \frac{137-1}{137-6-1} \times (1 - 0.489) = 1 - \frac{136}{130} \times 0.569 = 0.47$$

Supuestos del modelo

Para que los estimadores de *MCO* sean MELI (Mejor Estimador Lineal Insesgado o BLUE, en inglés), deben satisfacerse las siguientes condiciones:

Media Condicional Nula ($E[u_i | X] = 0$). El término de error no contiene información relacionada con las variables explicativas ($\text{Cov}(X_k, u) = 0$).

Homocedasticidad ($\text{Var}(u_i | X) = \sigma^2$). La varianza del término de error es constante.

Ausencia de autocorrelación ($\text{Cov}(u_i, u_j | X) = 0, \forall i \neq j$). Los términos de error no están correlacionados entre sí a través del tiempo o entre diferentes observaciones.

Ausencia de Multicolinealidad Perfecta. Ninguna variable independiente es una función lineal exacta de otra. Si las variables independientes se encuentran fuertemente correlacionadas, será más difícil aislar sus efectos individuales.

Multicolinealidad

Ocurre cuando dos o más variables explicativas entregan información duplicada o muy similar, dificultando medir el efecto real de cada una por separado. La multicolinealidad puede ser:

Perfecta: Duplicación exacta de datos (ej. incluir el EBITDA en USD y en pesos chilenos en la misma regresión). En este caso, el programa eliminará la variable redundante del modelo.

Imperfecta: Las variables independientes se mueven muy juntas, por lo que es difícil separar el efecto individual. El modelo global parece muy bueno (R^2 elevado), pero las variables individuales muestran poca significancia o cambian bruscamente de signo.

Efecto de la multicolinealidad imperfecta en MCO

Estimadores insesgados: Los coeficientes $\hat{\beta}$ siguen siendo insesgados y consistentes.

Pérdida de precisión (varianzas muy altas): Mantiene la propiedad “BLUE” en teoría, pero las varianzas de las estimaciones aumentan considerablemente, reduciendo la precisión del modelo.

Errores estándar inflados: Al dispararse los errores estándar, los estadísticos t caen, haciendo que variables que sí son relevantes parezcan no significativas individualmente (a pesar de tener un R^2 alto o prueba F global significativa).

Alta sensibilidad en los coeficientes: Las estimaciones de los $\hat{\beta}$ se vuelven inestables; cambios en la especificación (agregar/eliminar variables) provocan saltos en su magnitud o incluso cambios de signo.

¿Cómo detectar la multicolinealidad imperfecta?

- Observas un R^2 global muy alto (el modelo explica el 85% de las variaciones del retorno o de las ventas), pero ninguno de los coeficientes individuales (t -stats) resulta estadísticamente significativo.
- Usar el *Factor de Inflación de Varianza (VIF)*. Mide cuánto se “infla” la incertidumbre de un coeficiente debido a la duplicación de información.

VIF = 1: Sin correlación (ideal)

VIF > 5: Alerta. Hay multicolinealidad moderada/alta.

VIF > 10: *Red flag grave*. La estimación del impacto individual no es confiable.

Multicolinealidad imperfecta: ¿Solución?

A diferencia de la heterocedasticidad o la autocorrelación donde simplemente se cambia la fórmula de los errores estándar, la multicolinealidad no se arregla ajustando los errores estándar. Entre las soluciones se cuentan:

Eliminar la variable menos relevante. Por ejemplo, si incluyes Ventas Totales y EBITDA y ambos están colineales, conserva solo la que responda a la pregunta directa del negocio.

Crear un Índice o Variable Compuesta. Por ejemplo, si usas 4 ratios de liquidez muy correlacionados, combínalos en un único Índice de Liquidez

Factor de inflación de varianza para NVDA y XOM, Especificación (5)

Factor	VIF
HML	2.115551
CMA	1.900494
SMB	1.590030
MOM	1.355001
RMW	1.250231
Mkt_RF	1.221063

Nota: Los VIF son los mismos para NVDA y XOM ¿Por qué?

Heterocedasticidad

Supone que la varianza cambia para distintas observaciones:

$$\text{Var}(e_i \mid X_i) = \sigma_i^2$$

Nota que, en el caso de homocedasticidad,
 $\text{Var}(e_i \mid X_i) = \sigma^2$.

Efecto de la heterocedasticidad

Estimadores insesgados: Los coeficientes $\hat{\beta}$ mantienen su propiedad de insesgadez y consistencia.

Pérdida de eficiencia: Los estimadores ya no tienen la menor varianza (pierden la propiedad “BLUE”).



Errores estándar incorrectos: Las varianzas y errores estándar calculados por MCO estándar resultan sesgados. Puede sesgar los errores estándar hacia arriba o hacia abajo.

Pruebas t y F inválidas: Al distorsionar los errores estándar, las inferencias estadísticas fallan, aumentando el riesgo de tomar decisiones o conclusiones equivocadas sobre la significancia de las variables.

Heterocedasticidad en datos financieros

Agrupamiento de volatilidad (volatility clustering): En mercados financieros, los períodos de alta volatilidad suelen estar seguidos por alta volatilidad, y los de calma por calma. Esto provoca que la varianza de los residuos cambie dinámicamente con el tiempo.

Efecto Tamaño y Crecimiento: Empresas de mayor capitalización o con un crecimiento acelerado presentan una dispersión de rendimientos mucho mayor frente a eventos macroeconómicos que firmas maduras o estables.



Corrección de errores estándar: HC1 y HC3

Cuando existe heterocedasticidad, corregimos la matriz de varianzas-covarianzas sin modificar los coeficientes β :

HC1 (Huber-White): Es el estándar en otros programas y en econometría clásica. Usando la librería `statsmodels` se incluye `.fit(cov_type='HC1')`.

HC3 (MacKinnon & White): Se considera superior a HC1 en muestras pequeñas o cuando hay observaciones influyentes, ya que previene el sesgo a la baja de los errores estándar robustos. Usando la librería `statsmodels` se incluye `.fit(cov_type='HC3')`.

Resultados de estimaciones por MCO para NVDA (Errores HC1)

	Y				
	(1)	(2)	(3)	(4)	(5)
Mkt_RF	1.703*** (0.233)	1.733*** (0.214)	1.711*** (0.221)	1.645*** (0.232)	1.643*** (0.237)
SMB		-0.262 (0.313)	-0.293 (0.300)	-0.194 (0.348)	-0.198 (0.340)
HML		-0.896*** (0.252)	-0.919*** (0.268)	-0.656** (0.290)	-0.659** (0.306)
MOM			-0.098 (0.238)		-0.009 (0.244)
RMW				0.415 (0.442)	0.412 (0.452)
CMA				-0.727 (0.479)	-0.725 (0.482)
Intercept	3.435*** (0.967)	3.358*** (0.916)	3.408*** (0.950)	3.362*** (0.913)	3.366*** (0.943)
Observations	137	137	137	137	137
R ²	0.341	0.418	0.419	0.431	0.431

Significance levels: * p < 0.1, ** p < 0.05, *** p < 0.01. Format of coefficient cell: Coefficient (Std. Error)

Resultados de estimaciones por MCO para NVDA (Errores HC3)

	Y				
	(1)	(2)	(3)	(4)	(5)
Mkt_RF	1.703*** (0.244)	1.733*** (0.225)	1.711*** (0.234)	1.645*** (0.251)	1.643*** (0.259)
SMB		-0.262 (0.328)	-0.293 (0.315)	-0.194 (0.372)	-0.198 (0.365)
HML		-0.896*** (0.265)	-0.919*** (0.288)	-0.656** (0.316)	-0.659* (0.338)
MOM			-0.098 (0.265)		-0.009 (0.277)
RMW				0.415 (0.479)	0.412 (0.493)
CMA				-0.727 (0.518)	-0.725 (0.524)
Intercept	3.435*** (0.988)	3.358*** (0.948)	3.408*** (0.994)	3.362*** (0.964)	3.366*** (1.008)
Observations	137	137	137	137	137
R ²	0.341	0.418	0.419	0.431	0.431

Significance levels: * p < 0.1, ** p < 0.05, *** p < 0.01. Format of coefficient cell: Coefficient (Std. Error)

Resultados de estimaciones por MCO para XOM (Errores HC1)

	Y				
	(1)	(2)	(3)	(4)	(5)
Mkt_RF	0.743*** (0.190)	0.752*** (0.135)	0.711*** (0.146)	0.801*** (0.136)	0.764*** (0.143)
SMB		0.069 (0.215)	0.013 (0.224)	0.204 (0.225)	0.127 (0.232)
HML		1.078*** (0.203)	1.037*** (0.208)	0.779*** (0.259)	0.724*** (0.252)
MOM			-0.180 (0.171)		-0.195 (0.157)
RMW				0.257 (0.271)	0.193 (0.265)
CMA				0.580* (0.339)	0.633* (0.333)
Intercept	0.041 (0.659)	0.050 (0.486)	0.141 (0.492)	0.018 (0.485)	0.119 (0.493)
Observations	137	137	137	137	137
R ²	0.185	0.458	0.464	0.482	0.489

Significance levels: * p < 0.1, ** p < 0.05, *** p < 0.01. Format of coefficient cell: Coefficient (Std. Error)

Resultados de estimaciones por MCO para XOM (Errores HC3)

	Y				
	(1)	(2)	(3)	(4)	(5)
Mkt_RF	0.743*** (0.198)	0.752*** (0.142)	0.711*** (0.158)	0.801*** (0.146)	0.764*** (0.158)
SMB		0.069 (0.232)	0.013 (0.244)	0.204 (0.250)	0.127 (0.261)
HML		1.078*** (0.226)	1.037*** (0.232)	0.779*** (0.289)	0.724** (0.283)
MOM			-0.180 (0.187)		-0.195 (0.176)
RMW				0.257 (0.296)	0.193 (0.294)
CMA				0.580 (0.368)	0.633* (0.367)
Intercept	0.041 (0.677)	0.050 (0.508)	0.141 (0.518)	0.018 (0.518)	0.119 (0.532)
Observations	137	137	137	137	137
R ²	0.185	0.458	0.464	0.482	0.489

Significance levels: * p < 0.1, ** p < 0.05, *** p < 0.01. Format of coefficient cell: Coefficient (Std. Error)

Autocorrelación

Situación en la que existe una correlación entre las observaciones del término de perturbación (o error) a lo largo del tiempo.

Formalmente, el Modelo Clásico de Regresión Lineal asume que no hay correlación entre los términos de error correspondientes a diferentes observaciones:

$$\text{cov}(u_i, u_j) = 0 \quad \text{para } i \neq j$$

Cuando este supuesto se viola y los errores están correlacionados entre sí ($\text{cov}(u_i, u_j) \neq 0$), se dice que existe autocorrelación.

Autocorrelación: ¿positiva o negativa?

Autocorrelación positiva: cuando a un error positivo le tiende a seguir otro error positivo, o a uno negativo otro negativo.

Autocorrelación negativa: cuando los errores alternan continuamente de signo (a un error positivo le sigue uno negativo y viceversa).

Efecto de la autocorrelación en MCO

Estimadores insesgados: Los coeficientes $\hat{\beta}$ mantienen su propiedad de insesgadez y consistencia.

Pérdida de eficiencia: Los estimadores ya no tienen la menor varianza (pierden la propiedad “BLUE”).

Errores estándar incorrectos: Las varianzas y errores estándar calculados por MCO estándar resultan sesgados.



Pruebas t y F inválidas: Al subestimar los errores estándar (*autocorrelación positiva*), los estadísticos t y F se inflan, aumentando el riesgo de concluir erróneamente que una variable es significativa.

Autocorrelación en datos financieros

Retornos de los activos: Es casi nula en rendimientos diarios o de baja frecuencia debido a la eficiencia del mercado. Solo aparece en datos intradía (minuto a minuto) por la microestructura del mercado.

Volatilidad: Presenta alta autocorrelación (volatility clustering); rachas de alta volatilidad siguen a la alta volatilidad, y la calma a la calma.

Macroeconomía y finanzas agregadas: Es muy común en series como tasas de interés o tipos de cambio por la inercia de los ciclos económicos.



Corrección de errores estándar: HAC (Newey-West)

Cuando existe autocorrelación (o autocorrelación junto con heterocedasticidad), también ajustamos la matriz de varianzas-covarianzas sin modificar los coeficientes β :

HAC / Newey-West (HAC): Significa *Heteroskedasticity and Autocorrelation Consistent*. Es la corrección análoga a HC1/HC3 pero ajustada para autocorrelación, agregando términos de rezago (*lags*) a la estimación. En `statsmodels` se especifica con `.fit(cov_type='HAC', cov_kws={'maxlags': k})`.

Determinación de rezagos (lags): La corrección requiere definir cuántos rezagos (k) considerar. Una regla práctica en econometría financiera para datos de serie de tiempo es usar $k \approx T^{1/4}$ o un valor fijo según la frecuencia de los datos (por ejemplo, 4 para trimestrales, 12 para mensuales).

Resultados por MCO para NVDA (Errores HAC - Newey-West, 3 Lags)

	Y				
	(1)	(2)	(3)	(4)	(5)
Mkt_RF	1.703*** (0.287)	1.733*** (0.254)	1.711*** (0.270)	1.645*** (0.286)	1.643*** (0.298)
SMB		-0.262 (0.326)	-0.293 (0.315)	-0.194 (0.348)	-0.198 (0.340)
HML		-0.896*** (0.254)	-0.919*** (0.270)	-0.656** (0.254)	-0.659** (0.277)
MOM			-0.098 (0.282)		-0.009 (0.290)
RMW				0.415 (0.401)	0.412 (0.409)
CMA				-0.727 (0.483)	-0.725 (0.490)
Intercept	3.435*** (1.079)	3.358*** (1.012)	3.408*** (1.070)	3.362*** (1.026)	3.366*** (1.086)
Observations	137	137	137	137	137
R ²	0.341	0.418	0.419	0.431	0.431

Significance levels: * p < 0.1, ** p < 0.05, *** p < 0.01. Format of coefficient cell: Coefficient (Std. Error)

Resultados por MCO para XOM (Errores HAC - Newey-West, 3 Lags)

	Y				
	(1)	(2)	(3)	(4)	(5)
Mkt_RF	0.743*** (0.236)	0.752*** (0.153)	0.711*** (0.163)	0.801*** (0.154)	0.764*** (0.161)
SMB		0.069 (0.221)	0.013 (0.233)	0.204 (0.230)	0.127 (0.236)
HML		1.078*** (0.203)	1.037*** (0.206)	0.779*** (0.251)	0.724*** (0.241)
MOM			-0.180 (0.163)		-0.195 (0.146)
RMW				0.257 (0.328)	0.193 (0.318)
CMA				0.580* (0.300)	0.633** (0.292)
Intercept	0.041 (0.758)	0.050 (0.501)	0.141 (0.495)	0.018 (0.483)	0.119 (0.486)
Observations	137	137	137	137	137
R ²	0.185	0.458	0.464	0.482	0.489

Significance levels: * p < 0.1, ** p < 0.05, *** p < 0.01. Format of coefficient cell: Coefficient (Std. Error)

Regla de decisión

¿Datos de corte transversal (empresas, clientes, países en un único punto del tiempo)? Usa [HC3](#) (o [HC1](#)). Asume heterocedasticidad por diferencias de escala. *(Nota: si existe dependencia geográfica explícita, como precios de viviendas por barrio, se requiere corrección por autocorrelación espacial).*

¿Datos de series de tiempo (precios, retornos, datos mensuales/diarios a lo largo del tiempo)? Usa [HAC](#). Asume por defecto que las series financieras ordenadas en el tiempo tienen tanto heterocedasticidad como autocorrelación temporal.