

Regresión lineal múltiple

Parte II | Econometría Financiera

Víctor Macías E.

A continuación se analizarán los siguientes tópicos:


- Variables dummies
- Omisión de variable relevante
- Error de medición en la variable dependiente y regresores
- Error de especificación de forma funcional

Variables dummies

Estas variables convierten atributos cualitativos y eventos discretos en valores binarios (0 o 1), permitiendo medir su impacto en el valor, riesgo o rendimiento de un activo.

- *Macroeconomía*: Recesión ($D = 1$) vs. Expansión ($D = 0$) → Mide el cambio en el riesgo de mercado.
- *Renta Fija*: Grado de inversión ($D = 0$) vs. junk bond ($D = 1$) → Cuantifica el salto en el spread.
- *ESG*: Bono Verde ($D = 1$) vs. Tradicional ($D = 0$) → Determina el descuento en el costo de financiamiento.
- *Mercado Laboral*: Certificación de Magister en Finanzas ($D = 1$) vs. Sin grado ($D = 0$) → Aísla el premio salarial en las contrataciones en la industria financiera.

Las observaciones difieren en X y en el color



Tres especificaciones de modelos

Modelo A: $Y_i = \beta_0 + \beta_1 X_{1i} + \epsilon_i$

Modelo B: $Y_i = \beta_0 + \beta_1 X_{1i} + \beta_2 D_i + \epsilon_i$


Modelo C: $Y_i = \beta_0 + \beta_1 X_{1i} + \beta_2 D_i + \beta_3 (X_{1i} \times D_i) + \epsilon_i$

donde:

X_1 es una variable numérica continua

$$D = \begin{cases} 1, & \text{si es rojo} \\ 0, & \text{si es azul} \end{cases}$$

¿Cuál modelo eliges?



Interpretación de los coeficientes

Modelo A: La pendiente es la misma, el intercepto es el mismo

Pendiente: Los rojos y azules tienen la misma pendiente, β_1

Intercepto: Los rojos y azules tienen el mismo intercepto, β_0

Modelo B: La pendiente es la misma, el intercepto es diferente

Pendiente: Los rojos y azules tienen la misma pendiente, β_1

Intercepto: Son diferentes: (1) si es rojo, el intercepto es $\beta_0 + \beta_2$; (2) si es azul, el intercepto es β_0

Modelo C: La pendiente y el intercepto son diferentes

Pendiente: Son diferentes: (1) si es rojo, la pendiente es $\beta_1 + \beta_3$; (2) si es azul, la pendiente es β_1

Intercepto: Son diferentes: (1) si es rojo, el intercepto es $\beta_0 + \beta_2$; (2) si es azul, el intercepto es β_0

Aplicación: ¿Realmente paga un Magíster en Finanzas?

Sabes que a mayor experiencia laboral (X_1), mayor es el salario (Y). Sin embargo, te enfrentas al dilema de valorar la educación ejecutiva:

¿Un Magíster en Finanzas ($D = 1$) simplemente añade una prima fija al sueldo o cambia la velocidad a la que un profesional rentabiliza su experiencia?

Modelo A: Asume que la experiencia es lo único que importa. Asume que un profesional con Magister y uno sin este grado recorren exactamente la misma trayectoria salarial.

$$Y_i = \beta_0 + \beta_1 X_{1i} + \epsilon_i$$

Esta especificación genera *sesgo por variable omitida*. Al ignorar el grado académico, β_1 sobreestima el retorno de la experiencia pura al mezclar los sueldos de ambos grupos en una sola línea promedio.

Modelo B: El Magíster actúa como un sello de garantía o señalización de mercado. Poseer el título te otorga una prima salarial fija (β_2), independientemente de cuántos años lleves trabajando.

$$Y_i = \beta_0 + \beta_1 X_{1i} + \beta_2 D_i + u_i$$

- Sin Magíster ($D = 0$): $Y_i = \beta_0 + \beta_1 X_{1i}$
- Con Magíster ($D = 1$): $Y_i = (\beta_0 + \beta_2) + \beta_1 X_{1i}$

Ambas trayectorias crecen al mismo ritmo (β_1), pero quienes tienen el grado arrancan desde un peldaño salarial más alto.

Modelo C: El Magíster no solo te da un empujón inicial; multiplica el valor de cada año de experiencia futuro. Te da herramientas analíticas avanzadas y una red de contactos (*networking*) que hacen que tu curva de aprendizaje y tus ascensos sean más empinados.

$$Y_i = \beta_0 + \beta_1 X_{1i} + \beta_2 D_i + \beta_3 (X_{1i} \times D_i) + u_i$$

- Sin Magíster ($D = 0$): Pendiente = β_1
- Con Magíster ($D = 1$): Pendiente = $\beta_1 + \beta_3$

Si $\beta_3 > 0$, la brecha salarial entre alguien con y sin Magíster se ensancha con los años. Cada año adicional de experiencia le rinde más al profesional graduado que al no graduado.

¿Cuántas variables dummy se necesitan?

Para evitar la trampa de la variable dummy que genera problema de multicolinealidad perfecta en una regresión, la regla general es:

Se necesitan $k - 1$ variables dummies para representar una variable categórica que tiene k categorías.

Solo se puede incluir k variables dummies si se elimina explícitamente la constante (β_0) del modelo de regresión.

Interpretación respecto a la categoría base

- *Categoría de referencia (o base)*: La categoría omitida se convierte en el punto de comparación.
- *Interpretación*: Los coeficientes de las $k - 1$ dummies incluidas miden la diferencia de la variable dependiente respecto a esa categoría base.

Omisión de variable relevante

Considera el modelo “verdadero”:

$$Y_i = \beta_0 + \beta_1 X_i + \beta_2 Z_i + u_i$$

donde:

Y : variable dependiente (ej. valoración de la empresa, salario, retorno de la acción).

X : Variable explicativa clave en el modelo (ej. gastos en I+D, años de experiencia laboral, emisiones de CO_2).

Z : Variable omitida (ej. calidad de la administración, habilidades cognitivas, habilidades no-cognitivas, gobierno corporativo).

Si se estima el modelo omitiendo Z :

$$Y_i = \alpha_0 + \alpha_1 X_i + e_i$$

El coeficiente estimado por Mínimos Cuadrados Ordinarios (MCO), $\hat{\alpha}_1$, no mide únicamente el efecto directo de X sobre Y (β_1), sino que también absorbe el efecto de la variable que se omitió, Z .

En otras palabras,

$$\hat{\alpha}_1 = \beta_1 + \underbrace{\beta_2 \times \gamma_1}_{\text{Sesgo}}$$

donde:

β_2 es el efecto marginal de la variable omitida Z sobre Y .

$\gamma_1 = \frac{\text{Cov}(X,Z)}{\text{Var}(X)}$ representa el coeficiente de una regresión de la variable omitida Z sobre la variable X .

Signo del Sesgo

	$\beta_2 > 0$	$\beta_2 < 0$
$\gamma_1 > 0$	<i>Sesgo Positivo</i> $\hat{\alpha}_1 > \beta_1$ (Sobreestima el efecto de X)	<i>Sesgo Negativo</i> $\hat{\alpha}_1 < \beta_1$ (Subestima el efecto de X)
$\gamma_1 < 0$	<i>Sesgo Negativo</i> $\hat{\alpha}_1 < \beta_1$ (Subestima el efecto de X)	<i>Sesgo Positivo</i> $\hat{\alpha}_1 > \beta_1$ (Sobreestima el efecto de X)

Antes de aprobar un modelo cuantitativo o informe analítico, fórmúlate estas preguntas:

- ¿Existe un factor no observado Z que afecte a Y ? Si $\beta_2 \neq 0$, la variable es relevante.
- ¿Está ese factor Z relacionado con la variable X ? Si $\gamma_1 \neq 0$, existe sesgo y los coeficientes no se pueden interpretar en términos causales.

Error de medición

Si la variable que introduces en tu modelo tiene un error de medición, el impacto en los resultados depende de DÓNDE esté el error: si en la variable independiente (X) o en la variable dependiente (Y).

Caso 1: Error de medición en Y

Pregunta: *¿Cuántos millones de dólares adicionales vale una empresa en el mercado por cada millón de dólares adicional que genera de EBITDA?*

$$\text{Valor de Mercado}_i = \beta_0 + \beta_1 \text{EBITDA}_i + e_i$$

En el mundo real, el *valor de mercado verdadero* (Y^*) de una compañía no siempre se puede observar de forma directa o perfecta.


Se observa una proxy o un valor reportado: $Y = Y^* + w$.

¿Cómo explicar w ?

- Si la empresa no cotiza en Bolsa, el analista debe usar valores libro que no necesariamente representan el precio real al que se cerraría una transacción de compraventa hoy.
- El valor libro suele estar desactualizado respecto a las expectativas cambiantes de la economía y del negocio en particular.


	Modelo con Y^*	Modelo con Y
β_1 estimado (Verdadero = 8.0)	8.078	8.097
Error estándar de β_1	0.127	0.282
R^2	0.965	0.848

Modelo SIN error de medición



EBITDA (\$M)

Modelo CON error de medición



EBITDA (\$M)

En resumen, el error de medición en la variable dependiente tiene los siguientes efectos:

- El valor del coeficiente es insesgado. Nota cómo en ambos modelos el múltiplo estimado para el EBITDA se mantiene oscilando muy cerca del valor real de $8.0x$

Se asume que el error de medición no está relacionado con el EBITDA.

- El R^2 colapsa drásticamente en el modelo con error de medición en el valor de la empresa.
- El error estándar de $\hat{\beta}_1$ aumenta

Caso 2: Error de medición en X

Pregunta: *¿Cuánto aumenta el retorno accionario en exceso de la tasa libre de riesgo que exigen los inversionistas a una empresa por cada incremento del 1% en su nivel absoluto de emisiones de CO₂?*

$$\text{Retorno en Exceso}_{i,t} = \beta_0 + \beta_1 \log(\text{Emisiones}_{i,t-1}^*) + e_{i,t}$$


El nivel absoluto real de emisiones de carbono (Emisiones^* , medido en toneladas métricas de CO₂e) de una empresa, se observa en los datos con error de medición: $X = X^* + w$.

¿Cómo explicar w ?

- A menudo se imputan los niveles de emisiones absolutas para firmas que no divulgan datos, utilizando modelos basados en promedios sectoriales y tamaño.
- Errores de estimación en emisiones a lo largo de la cadena de suministro (aguas arriba y abajo).

	Modelo con X^*	Modelo con X
β_1 estimado (Verdadero = 0.800)	0.789	0.049
Error estándar de β_1	0.063	0.023
R^2	0.741	0.483

Evidencia visual del sesgo de atenuación



En resumen, el error de medición en las emisiones genera:

Sesgo de atenuación: $\hat{\beta}_1$ se reduce drásticamente hacia cero, haciendo parecer engañosamente que los inversionistas no exigen un rendimiento adicional por sostener firmas con altos volúmenes de emisiones.

Especificación incorrecta de forma funcional

Sucede cuando, por ejemplo, se asume que la relación entre dos variables es una línea recta (lineal), cuando en la realidad los datos responden a un comportamiento curvilíneo, exponencial o cuadrático.

Cuando se aplica la forma funcional incorrecta, la parte no explicada del modelo (los perturbaciones o residuos) tiende a mostrar patrones sistemáticos o no linealidades, lo que puede invalidar las pruebas de hipótesis estadísticas.

Soluciones

Transformación de Variables: Aplicar transformaciones logarítmicas a las variables para suavizar la varianza y convertir relaciones multiplicativas o no lineales en estructuras aditivas.

Agregar términos polinómicos: Incluir potencias de orden superior (por ejemplo, x^2) para capturar trayectorias en forma de “U” o de “U invertida”.

Modelos por partes o cambios de régimen: Si la relación cambia bruscamente a partir de un determinado umbral, se emplean modelos lineales por partes (*piecewise linear models*) o modelos de umbral.