

Regresión lineal simple

Econometría Financiera

Víctor Macías E.

En estas notas se usarán las siguientes librerías de Python:

```
1 import re
2 import matplotlib.pyplot as plt
3 import numpy as np
4 import pandas as pd
5 import seaborn as sns
6 import statsmodels.api as sm
7 import statsmodels.formula.api as smf
8 import yfinance as yf
9 from scipy import stats
```

El Modelo Poblacional

El *proceso generador de datos* o *modelo poblacional* describe la relación funcional entre las variables:

$$y_t = \alpha + \beta x_t + u_t$$

donde α y β representan los parámetros verdaderos y no observables del proceso.

💡 Dado que la población no es observable, recurrimos a estimar $\hat{\alpha}$ y $\hat{\beta}$ usando *Mínimos Cuadrados Ordinarios (MCO)*. Al cambiar la ventana temporal o la frecuencia de los datos (diaria, mensual, trimestral) se modificarán las estimaciones.

Nombres para y : variable dependiente, variable explicada, variable de respuesta, variable predicha o regresando.

Nombres para x : variable independiente, variable explicativa, variable de control, predictor o regresor.

u es el término error o perturbación.

¡La regresión lineal múltiple incluye más de un regresor!

¿Por qué incluir un término de error?

El término de error (u_t) incluye:

- *Factores omitidos o no observables*: Variables difíciles de medir o cuantificar (ej. cambios regulatorios, calidad de la gerencia o noticias específicas de la empresa).
- *Errores de medición*: Fricciones e imprecisiones inherentes a los datos observados de y_t .

¿Qué significa *lineal* en *regresión lineal*?

El modelo debe ser lineal en los parámetros (α y β), pero no necesariamente debe ser lineal en las variables x e y . Esto significa que los parámetros no son multiplicados, divididos, elevados al cuadrado, etc.

¿Es *lineal* el siguiente modelo?

$$y_t = \alpha + \beta x_t^\gamma + u_t$$

Ejemplo 1:

El modelo $y_t = Ax_t^\beta e^{u_t}$ se puede transformar a $\ln y_t = \ln(A) + \beta \ln x_t + u_t$ y el modelo a estimar por MCO es:

$$\ln y_t = \alpha + \beta \ln x_t + u_t$$

donde $\alpha = \ln(A)$ y β es interpretado como elasticidad. Por ejemplo, si $\hat{\beta} = 1.2$, entonces un incremento de 1% en x está asociado a un aumento en y de 1.2%.

Ejemplo 2:

El modelo: $y_t = \alpha + \frac{\beta}{x_t} + u_t$ se puede estimar por MCO como:

$$y_t = \alpha + \beta z_t + u_t$$

donde $z_t = \frac{1}{x_t}$

💡 Logaritmos en el modelo de regresión

Caso 1: Un 1% de cambio en x está asociado con un cambio en y de $\beta\%$, por lo que β es la elasticidad de y respecto a x .

$$\ln y = \alpha + \beta \ln x + u$$

Caso 2: Un 1% de cambio en x está asociado con un cambio en y de 0.01β

$$y = \alpha + \beta \ln x + u$$

Caso 3: Un cambio en x de una unidad está asociado con un cambio en y de $100\beta\%$.

$$\ln y = \alpha + \beta x + u$$

¡Todos estos modelos son regresiones lineales porque son lineales en los parámetros!

Estimación de los parámetros por MCO

Existen varios métodos para estimar α y β en el modelo $y_t = \alpha + \beta x_t + u_t$ a partir de una muestra. Sin embargo, nos enfocaremos en **Mínimos Cuadrados Ordinarios (MCO)**

Problema: Encontrar $\hat{\alpha}$ y $\hat{\beta}$ que minimizan la suma de los residuos al cuadrado $\sum_{t=1}^T \hat{u}_t^2 = \hat{u}_1^2 + \hat{u}_2^2 + \dots + \hat{u}_T^2 = \sum_{t=1}^T (y_t - \hat{\alpha} - \hat{\beta} x_t)^2$

donde $\hat{u}_t = y_t - \hat{y}_t = y_t - \hat{\alpha} - \hat{\beta} x_t$

Los valores de $\hat{\alpha}$ y $\hat{\beta}$ que minimizan $\sum_{t=1}^T \hat{u}_t^2$ son:

$$\hat{\beta} = \frac{\text{cov}(x_t, y_t)}{\text{var}(x_t)} = \frac{\sum_{t=1}^T (x_t - \bar{x})(y_t - \bar{y})}{\sum_{t=1}^T (x_t - \bar{x})^2}$$

$$\hat{\alpha} = \bar{y} - \hat{\beta}\bar{x}$$

Estas fórmulas representan a los estimadores de MCO que permiten calcular los coeficientes del modelo a partir de una muestra.

¿Qué ocurre si todos los valores de x'_t son iguales?

- Dado que $\hat{\alpha} = \bar{y} - \hat{\beta}\bar{x}$, la línea de regresión pasa por el punto $(\bar{x}, \bar{y})$
- Dado que $r_{xy} = \frac{cov(x,y)}{s_x s_y}$, se puede reemplazar $cov(x, y) = r_{xy} s_x s_y$

$$\hat{\beta} = \frac{cov(x, y)}{var(x)} = \frac{r_{xy} s_x s_y}{s_x^2} = r_{xy} \left(\frac{s_y}{s_x} \right)$$

Por lo tanto, el signo de $\hat{\beta}$ es el mismo que el del coeficiente de correlación entre x e y .

Reemplazando $\hat{\alpha}$ y $\hat{\beta}$ en el modelo especificado, se obtiene la línea de regresión:

$$\hat{y}_t = \hat{\alpha} - \hat{\beta}x_t$$

donde $\hat{y}_t$ son los valores predichos.

El residuo ($\hat{u}_t$) es igual a:

$$\hat{u}_t = y_t - \hat{y}_t$$

¡Errores son distintos a los residuos! $u_t \neq \hat{u}_t$

Medida de bondad del ajuste: R^2

Coeficiente de determinación (R^2). Mide la proporción de la varianza de la variable dependiente, y , que es explicada por la variable independiente x . Se calcula como:

$$R^2 = 1 - \frac{SRC}{STC}$$

donde $SRC = \sum_{t=1}^n (y_t - \hat{y})^2$ (suma de residuos al cuadrado) y $STC = \sum_{t=1}^n (y_t - \bar{y})^2$ (suma total de cuadrados)

En un modelo de regresión lineal simple, $R^2 = r_{xy}^2$. Dado que $-1 \leq r_{xy} \leq 1$, entonces $0 \leq R^2 \leq 1$.

Distribución muestral de los estimadores MCO

Si los errores (u_t) se distribuyen normalmente, $u_t \sim N(0, \sigma^2)$, entonces:

$$\hat{\alpha} \sim N(\alpha, \text{var}(\hat{\alpha}))$$

$$\hat{\beta} \sim N(\beta, \text{var}(\hat{\beta}))$$

Si los errores (u_t) no se distribuyen normalmente, entonces $\hat{\alpha}$ y $\hat{\beta}$ aún se distribuyen normalmente si el tamaño de la muestra es suficientemente grande.

Errores estándar

$$ee(\hat{\alpha}) = \hat{\sigma} \sqrt{\frac{\sum_{t=1}^T x_t^2}{T \sum_{t=1}^T (x_t - \bar{x})^2}}$$

$$ee(\hat{\beta}) = \hat{\sigma} \sqrt{\frac{1}{\sum_{t=1}^T (x_t - \bar{x})^2}}$$

donde $\hat{\sigma}$ es el estimador de σ y se le llama *error estándar de la regresión*, *error estándar de los residuos* o *raíz del error cuadrático medio*. El error estándar de la regresión se calcula como:

$$\hat{\sigma} = \sqrt{\frac{\sum_{t=1}^T \hat{u}_t^2}{T-2}}$$

Distribución t para estimadores estandarizados

$$\frac{\hat{\alpha} - \alpha}{ee(\hat{\alpha})} \sim t_{T-2}$$

$$\frac{\hat{\beta} - \beta}{ee(\hat{\beta})} \sim t_{T-2}$$

En un modelo de regresión lineal múltiple, se usa t_{T-k-1} , donde k es el número de regresores.

Prueba de hipótesis para un sólo parámetro

Sea el modelo: $y = \alpha + \beta x + u$. Se desea realizar el siguiente contraste de hipótesis:

$$H_0 : \beta = \beta_0$$

$$H_1 : \beta \neq \beta_0$$

En este caso, el estadístico de prueba t es igual a:

$$t = \frac{\hat{\beta} - \beta_0}{ee(\hat{\beta})} \sim t_{T-2}$$

Si el número de grados de libertad es grande, no necesitas usar la distribución t -Student y puedes trabajar directamente con la distribución normal.

*¿Cómo formularías una prueba de la cola inferior para β ?
¿Y de la cola superior? ¿una prueba de hipótesis para α ?*



Para implementar una prueba de hipótesis hay tres métodos:

Valor-p. Se rechaza H_0 si el $p\text{-value} \leq \alpha$

Valor crítico. Se rechaza H_0 si el valor absoluto calculado para el estadístico de prueba, t , es mayor al valor absoluto del valor crítico.

Intervalo de confianza. El IC para un parámetro poblacional, β , es igual a:

$$\hat{\beta} \pm t_{\alpha/2} ee(\hat{\beta})$$

Este método se usa en una prueba de hipótesis de dos colas. Se rechaza H_0 , si el IC no incluye a β_0 .

Aplicación:

Usando datos mensuales, se estima por MCO el siguiente modelo para el período Agosto 2021 hasta Agosto 2026:

$$R_{SBUX} = \alpha + \beta R_M + u$$

donde:

R_{SBUX} es el retorno mensual de la acción de Starbucks.

R_M es el retorno mensual del S&P500.

En este caso, los estimadores de MCO son:

$$\hat{\beta}^{MCO} = \frac{cov(R_{SBUX}, R_M)}{var(R_M)}$$

$$\hat{\alpha}^{MCO} = \bar{R}_{SBUX} - \hat{\beta}^{MCO} \bar{R}_M$$

A continuación se descargará desde Yahoo Finance el precio de cierre mensual ajustado de Starbucks (*SBUX*) y los valores del S&P500 (*^GSPC*) para los últimos cinco años.

```
1 tickers = ['SBUX', '^GSPC']
2 datos = yf.download(tickers, start='2021-08-04', end='2026-08-04', interval='1mo', auto_adjust=True)['Close']
```

Las primeras 10 observaciones son:

```
1 print(datos[['SBUX', '^GSPC']].head(10))
```

Ticker	SBUX	^GSPC
Date		
2021-09-01	98.545250	4307.540039
2021-10-01	94.757477	4605.379883
2021-11-01	98.369057	4567.000000
2021-12-01	104.945534	4766.180176
2022-01-01	88.212746	4515.549805
2022-02-01	82.771584	4373.939941
2022-03-01	82.032158	4530.410156
2022-04-01	67.306602	4131.930176
2022-05-01	71.285919	4132.149902
2022-06-01	69.369827	3785.379883

La variación porcentual mensual se calcula a continuación:

```
1 # Calcular retornos porcentuales mensuales
2 retornos = datos.pct_change().dropna()
3 retornos['R_SBUX'] = retornos['SBUX']*100
4 retornos['R_M'] = retornos['^GSPC']*100
5
6 print(retornos[['R_SBUX', 'R_M']].head(10))
```

Ticker	R_SBUX	R_M
Date		
2021-10-01	-3.843689	6.914384
2021-11-01	3.811393	-0.833371
2021-12-01	6.685514	4.361291
2022-01-01	-15.944259	-5.258517
2022-02-01	-6.168227	-3.136049
2022-03-01	-0.893333	3.577329
2022-04-01	-17.950955	-8.795671
2022-05-01	5.912223	0.005318
2022-06-01	-2.687897	-8.392000
2022-07-01	10.983111	9.111639

Estadística descriptiva


```
1 resumen = (retornos[['R_SBUX', 'R_M']]).agg([
2     'count', 'mean', 'std', 'min', lambda x: x.quantile(0.25), 'median', lambda x: x.quantile(0.75), 'max'])
3
4 resumen.index = [
5     'Observaciones', 'Media (%)', 'Desv. Estándar (%)', 'Mínimo (%)', 'Q1 (%)', 'Mediana (%)', 'Q3 (%)', 'Máximo (%)']
6
7 resumen.round(2)
```

Ticker	R_SBUX	R_M
Observaciones	59.00	59.00
Media (%)	0.45	1.07
Desv. Estándar (%)	8.64	4.54
Mínimo (%)	-18.39	-9.34
Q1 (%)	-3.77	-1.60
Mediana (%)	0.13	1.48
Q3 (%)	5.76	4.39
Máximo (%)	22.05	10.42

```

1 plt.figure(figsize=(8, 5))
2 sns.regplot(x='R_M', y='R_SBUX', data=retornos, ci=None, scatter_kws={'alpha':0.6, 'color':'#1f77b4', 's': 20},
3             line_kws={'color':'#860B0C', 'linewidth': 1.5, 'linestyle': '--'})
4 plt.title('SBUX vs. S&P 500, 2021-2026')
5 plt.xlabel('Retorno mensual S&P500 (%)')
6 plt.ylabel('Retorno mensual Starbucks (%)')
7 plt.grid(True, linestyle='--', alpha=0.5)
8 plt.show()

```



A continuación se calcula la covarianza y la correlación de los retornos:

```
1 cov = (retornos['R_SBUX']).cov(retornos['R_M']) # cálculo de la covarianza
2 cor = (retornos['R_SBUX']).corr(retornos['R_M']) # cálculo de la correlación
3
4 print(f"Covarianza: {cov:,.3f}")
5 print(f"Correlación: {cor:,.3f}")
```

Covarianza: 19.999

Correlación: 0.510

Nota que la correlación entre los retornos mensuales de Starbucks y del S&P500 se puede obtener como:

$$r = \frac{19.999}{8.64 \times 4.54} = 0.51$$

Los resultados de la estimación por MCO se presentan a continuación:

```
1 retornos_con_constante = sm.add_constant(retornos)
2 modelo1 = sm.OLS(retornos_con_constante['R_SBUX'], retornos_con_constante[['const', 'R_M']]).fit()
3 print(modelo1.summary())
```

OLS Regression Results						
=====						
Dep. Variable:	R_SBUX	R-squared:	0.260			
Model:	OLS	Adj. R-squared:	0.247			
Method:	Least Squares	F-statistic:	20.01			
Date:	Wed, 05 Aug 2026	Prob (F-statistic):	3.72e-05			
Time:	20:59:28	Log-Likelihood:	-201.55			
No. Observations:	59	AIC:	407.1			
Df Residuals:	57	BIC:	411.3			
Df Model:	1					
Covariance Type:	nonrobust					
=====						
	coef	std err	t	P> t	[0.025	0.975]

const	-0.5886	1.003	-0.587	0.560	-2.597	1.420
R_M	0.9697	0.217	4.474	0.000	0.536	1.404
=====						
Omnibus:	0.929	Durbin-Watson:		1.974		
Prob(Omnibus):	0.628	Jarque-Bera (JB):		0.550		
Skew:	0.232	Prob(JB):		0.760		
Kurtosis:	3.088	Cond. No.		4.77		
=====						

Notes:
[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.

El modelo estimado es:

$$\hat{R}_{SBUX} = -0.59 + 0.97\hat{R}_M$$

donde:

$$\hat{\beta} = \frac{19.999}{4.54^2} = 0.97$$

$$\hat{\alpha} = 0.45 - 0.97 \times 1.07 = -0.59$$

Nota que $R^2 = r^2 = 0.51^2 = 0.26$ (*Bondad de ajuste*)

Prueba de hipótesis:

$$H_0 : \beta = 0$$

$$H_1 : \beta \neq 0$$

Usando $\alpha = 0.05$ ¿Qué puedes concluir?

Nota: Se utilizarán los tres métodos discutidos anteriormente para realizar esta prueba de hipótesis.

Método del valor crítico:

$$t = \frac{\hat{\beta} - 0}{ee(\hat{\beta})} = \frac{\hat{\beta}}{ee(\hat{\beta})} = \frac{0.9697}{0.217} = 4.47$$

```
1 alpha = 0.05
2 n = 59
3 t_critico = abs(stats.t.ppf(alpha/2, df=n-2))
4 print(f"Estadístico t (valor crítico): {t_critico:.3f}")
```

Estadístico t (valor crítico): 2.002

Dado que $4.47 > 2.002$, se rechaza H_0 .

Método del p-value:

```
1 p_value = 2 * (1 - stats.t.cdf(4.47, df=n-2)) # p-valor para prueba de dos colas
2 print(f"p-value:          {p_value:.5f}")
```

p-value: 0.00004

Dado que $p\text{-value} < 0.05$, se rechaza H_0 .

Método del intervalo de confianza:

$$IC = \hat{\beta} \pm t_{\alpha/2} \times ES(\hat{\beta})$$

$$IC = 0.97 \pm 2.002 \times 0.217$$

donde el límite inferior es 0.536 y el límite superior es 1.404.

Dado que este intervalo no incluye el 0, se rechaza H_0 .

Continuando con el ejemplo anterior, ¿Cómo realizar la siguiente prueba de hipótesis?

$$H_0 : \beta = 1$$

$$H_1 : \beta \neq 1$$

Usando $\alpha = 0.05$ ¿Qué puedes concluir?

El valor del estadístico de prueba es:

$$t = \frac{0.9697 - 1}{0.217} = -0.1396$$

```
1 p_value = 2 * stats.t.cdf(-0.1396, df=n-2) # p-valor para prueba de dos colas
2 print(f"p-value: {p_value:.5f}")
```

p-value: 0.88947

Dado que $\text{p-value} > 0.05$, no se rechaza H_0 .