

Series de Tiempo

Parte I | Econometría Financiera

Víctor Macías E.

A continuación se analizarán los siguientes modelos:

- ARMA
- ARIMA
- SARIMA

¿Podemos usar el pasado para predecir?

- *Caso 1: el dólar contra su propio pasado.* Si el dólar salta de \$700 a \$900 por un choque de mercado ¿Volverá a los \$700 o los \$900 constituyen un nuevo equilibrio?
- *Caso 2: el dólar en función del precio del cobre.* Si el precio del dólar y del cobre suben o bajan al mismo tiempo por casualidad o por tendencias independientes, una regresión simple puede indicar erróneamente que el cobre explica el 90% de la variación del dólar (Regresión Espuria). En realidad, no existe una relación de largo plazo entre ambos.

Pregunta clave: ¿Existe “efecto resorte”?

¿El impacto de un shock se queda para siempre en la serie o la serie tiene un “resorte” que la regresa a su promedio histórico?

- Sin “resorte”: *Serie no estacionaria*. Cada cambio aleatorio se suma al valor anterior de forma permanente. La serie “camina” sin un ancla.
- Con “resorte”: *serie estacionaria*. La serie puede alejarse temporalmente de su nivel medio debido a un shock, pero el “resorte” tira de ella de vuelta a su promedio.

Para evitar regresiones espurias y construir modelos sólidos, debemos trabajar con estructuras donde las propiedades estadísticas no cambien en el tiempo. A esta propiedad se le llama estacionariedad.

Estacionariedad en sentido débil

Una serie de tiempo Y_t es estacionaria en sentido débil o estacionaria en covarianza si su distribución teórica fluctúa alrededor de un equilibrio constante:

- $E(Y_t) = \mu \quad \forall t$
- $\text{Var}(Y_t) = \sigma^2 \quad \forall t$
- $\text{Cov}(Y_t, Y_{t-h}) = \gamma_h$ (solo depende del rezago h , no del tiempo t)

Una serie es estacionaria cuando su media, varianza y autocovarianza son constantes a lo largo del tiempo: no presenta tendencias ni cambios estructurales.

Función de autocorrelación (ACF): mide el grado de asociación o correlación lineal entre la variable en el periodo actual (y_t) y sus valores pasados o rezagados (y_{t-k}).




Función de autocorrelación parcial (PACF): mide la correlación entre y_t y un rezago específico y_{t-k} , controlando o eliminando los efectos lineales indirectos de todos los rezagos intermedios ($y_{t-1}, y_{t-2}, \dots, y_{t-k+1}$).

Proceso de ruido blanco

- $E(Y_t) = 0 \quad \forall t$
- $\text{Var}(Y_t) = \sigma^2 \quad \forall t$
- $\text{Cov}(Y_t, Y_{t-h}) = 0 \quad \forall h \text{ y } t$

Un proceso de ruido blanco es estacionario y está representado por:

$$y_t = \epsilon_t$$



Proceso autorregresivo (AR)

Modelo $AR(p)$




$$y_t = \alpha_0 + \alpha_1 y_{t-1} + \alpha_2 y_{t-2} + \cdots + \alpha_p y_{t-p} + \epsilon_t$$

Modelo $AR(1)$

$$y_t = \alpha_0 + \alpha_1 y_{t-1} + \epsilon_t$$

Este proceso es estacionario si $|\alpha_1| < 1$

PACF identifica orden p del AR(p)



Proceso de media móvil (MA)

Modelo $MA(q)$




$$y_t = \alpha_0 + \theta_1 \epsilon_{t-1} + \theta_2 \epsilon_{t-2} + \cdots + \theta_q \epsilon_{t-q} + \epsilon_t$$

Modelo $MA(1)$

$$y_t = \alpha_0 + \theta_1 \epsilon_{t-1} + \epsilon_t$$

Estos procesos son siempre estacionarios.

ACF identifica orden q del MA(q)



Procesos ARMA




Modelo $ARMA(p, q)$

$$y_t = \alpha_0 + \alpha_1 y_{t-1} + \alpha_2 y_{t-2} + \cdots + \alpha_p y_{t-p} + \theta_1 \epsilon_{t-1} + \theta_2 \epsilon_{t-2} + \cdots + \theta_q \epsilon_{t-q}$$

Modelo $ARMA(1, 1)$

$$y_t = \alpha_0 + \alpha_1 y_{t-1} + \theta_1 \epsilon_{t-1} + \epsilon_t$$

Este proceso es estacionario si $|\alpha_1| < 1$ y $|\theta_1| < 1$.









Procesos no estacionarios




Tendencia determinística: $y_t = \alpha_0 + \delta t + \epsilon_t$ (Estacionario en tendencia)




Tendencia estocástica:

- Paseo aleatorio (random walk): $y_t = y_{t-1} + \epsilon_t$
- Paseo aleatorio (random walk with drift): $y_t = \alpha_0 + y_{t-1} + \epsilon_t$
- Paseo aleatorio (random walk with drift and trend):
 $y_t = \alpha_0 + \delta t + y_{t-1} + \epsilon_t$










Caso 1: S&P500 - No estacionariedad




S&P500 es una serie no estacionaria. Aplicar la primera diferencia mediante log-retornos es indispensable para remover la tendencia estocástica y hacer la serie estacionaria.

Caso 2: *VIX* - Estacionariedad


- Mide la volatilidad implícita a 30 días de las opciones del S&P 500 y tiende a fluctuar alrededor de una media histórica, aunque experimenta picos por eventos de estrés.
- Exhibe dinámica de reversión a la media:

Tras un salto abrupto, el VIX regresa a su promedio histórico entre 15 y 20 puntos.


VIX | 3 de enero de 2018 al 17 de septiembre de 2026



Autocorrelación (ACF)



Autocorrelación Parcial (PACF)



VIX es una serie estacionaria con una clara propiedad de reversión a la media. No se debe diferenciar.

Pruebas Formales: Test de Dickey-Fuller Aumentado (ADF)

Evaluamos la presencia de raíz unitaria mediante la regresión:

$$\Delta Y_t = \alpha + \beta Y_{t-1} + \sum_{i=1}^p \gamma_i \Delta Y_{t-1-i} + \epsilon_t$$

$H_0 : \beta = 0$: La serie no es estacionaria (tiene raíz unitaria)

$H_1 : \beta < 0$: A mayor valor ayer (Y_{t-1}), mayor presión a la baja hoy ($\Delta Y_t < 0$). La serie es estacionaria.


```
1 # PRUEBA ADF: S&P 500
2 adf_sp500 = adfuller(df['^GSPC'].dropna())
3 p_val = adf_sp500[1]
4 estado = 'No Estacionaria' if p_val >= 0.05 else 'Estacionaria'
5
6 print(f"S&P 500 | Estadístico ADF: {adf_sp500[0]:.2f} | p-value: {p_val:.4f} | {estado}")
```

S&P 500 | Estadístico ADF: 0.64 | p-value: 0.9886 | No Estacionaria

```
1 # PRUEBA ADF: VIX
2 adf_vix = adfuller(df['^VIX'].dropna())
3 p_val = adf_vix[1]
4 estado = 'No Estacionaria' if p_val >= 0.05 else 'Estacionaria'
5
6 print(f"VIX | Estadístico ADF: {adf_vix[0]:.2f} | p-value: {p_val:.4f} | {estado}")
```

VIX | Estadístico ADF: -5.42 | p-value: 0.0000 | Estacionaria


```
1 # Cálculo de log-retornos del S&P 500
2 sp500_returns = np.log(df['^GSPC'] / df['^GSPC'].shift(1)).dropna()
```



```
1 adf_ret = adfuller(sp500_returns)
2 p_val_ret = adf_ret[1]
3 est_ret = 'No Estacionaria' if p_val_ret >= 0.05 else 'Estacionaria'
4
5 print(f"S&P 500 (Retornos) | Estadístico ADF: {adf_ret[0]:.2f} | p-value: {p_val_ret:.4f} | {est_ret}")
```

S&P 500 (Retornos) | Estadístico ADF: -14.78 | p-value: 0.0000 | Estacionaria

Retornos S&P500




Caso 3: Ventas de Energía: Estacionalidad y tendencia


Clientes regulados: recibe el suministro eléctrico con precios y condiciones fijadas por la Comisión Nacional de Energía. Tienen una potencia menor a 300 kW.

Clientes libres: pueden elegir de donde reciben su energía negociando precio y plazos. Tienen una potencia mayor a 300 kW.


Ventas mensuales a clientes regulados | Enero 2019 - Junio 2026



Autocorrelación (ACF)




Autocorrelación Parcial (PACF)




Para lograr estacionariedad, se aplica doble diferenciación ($\Delta\Delta_{12}y_t$). Primero, una diferenciación estacional de orden 12 ($\Delta_{12}y_t = y_t - y_{t-12}$) para remover el patrón anual (restando a las ventas de cada mes las del mismo mes del año anterior, ej. Junio 2025 vs. Junio 2024). Posteriormente, una diferenciación regular de primer orden (Δ) para eliminar la inercia o tendencia de corto plazo de un mes a otro. La doble diferenciación ($\Delta\Delta_{12}y_t$) es necesaria porque la diferencia estacional por sí sola no elimina la persistencia de corto plazo.


Ventas a clientes regulados — Doble Diferenciación ($\Delta\Delta_{12}y_t$)




Autocorrelación (ACF)




Autocorrelación Parcial (PACF)




Ventas mensuales a clientes libres | Enero 2019 - Junio 2026




Autocorrelación (ACF)




Autocorrelación Parcial (PACF)




Ventas a clientes libres — Diferenciación (Δy_t)



Autocorrelación (ACF)



Autocorrelación Parcial (PACF)



Para lograr estacionariedad en la serie de clientes libres, se aplica únicamente una diferenciación regular de primer orden ($\Delta y_t = y_t - y_{t-1}$). Esta transformación elimina la marcada tendencia estocástica de largo plazo (restando a las ventas de cada mes las del mes inmediatamente anterior, ej. Junio 2025 vs. Mayo 2025). A diferencia del segmento regulado, no se requiere una diferencia estacional adicional (Δ_{12}), ya que forzar una doble diferenciación genera sobrediferenciación y distorsiona la estructura estacional subyacente, la cual se modela de forma directa mediante la componente estacional del SARIMA.

```
1 # CLIENTES LIBRES: Test ADF evaluando Tendencia Alcista ('ct')
2
3 # 'ct' = Constant + Trend (Evalúa si es estacionaria alrededor de una tendencia)
4 adf_libres = adfuller(energia['libre'].dropna(), regression='ct')
5 p_libres = adf_libres[1]
6
7 print(f"Clientes Libres (Niveles) | p-value: {p_libres:.4f} | "
8       f"'No Estacionaria (Requiere Diferenciación)' if p_libres >= 0.05 else 'Estacionaria con Tendencia'")
```

Clientes Libres (Niveles) | p-value: 0.2361 | No Estacionaria (Requiere Diferenciación)

```
1 # CLIENTES REGULADOS: Eliminación de Estacionalidad previo al Test
2
3 # Diferenciación a 12 meses (Compara Enero vs Enero del año anterior)
4 regulados_diff12 = energia['regulado'].diff(12).dropna()
5
6 adf_reg = adfuller(regulados_diff12, regression='c')
7 p_reg = adf_reg[1]
8
9 print(
10     f"Clientes Regulados (Diff 12M) | p-value: {p_reg:.4f} | "
11     f"{'No Estacionaria' if p_reg >= 0.05 else 'Estacionaria (Lista para Pronóstico)'}")
```

Clientes Regulados (Diff 12M) | p-value: 0.0235 | Estacionaria (Lista para Pronóstico)

Hacia proyecciones confiables

¿Qué pasos seguir para transformar datos históricos en proyecciones confiables para la toma de decisiones?

PASO 1: Diagnóstico visual

PASO 2: Evaluación de estacionariedad y transformación

PASO 3: Identificación y selección del modelo

PASO 4: Validación, estimación y evaluación

PASO 5: Generación de pronósticos

Paso 1: Diagnóstico visual

Antes de ejecutar pruebas cuantitativas, se debe inspeccionar la serie e interpretar la dinámica económica subyacente:

- **Tendencia:** Crecimiento o decrecimiento sostenido impulsado por inflación, actividad económica o expansión de mercado.
- **Estacionalidad:** Patrones cíclicos repetitivos vinculados a variables climáticas, hábitos de consumo (compras navideñas), número de días hábiles en el mes, etc.
- **Quiebres estructurales y volatilidad:** Saltos drásticos o cambios estructurales derivados de crisis financieras, eventos geopolíticos o shocks de mercado.

Paso 2: Evaluación de estacionariedad y transformación de datos

Dado que las series financieras en niveles rara vez son estacionarias, se diagnostica la estructura temporal antes de modelar:

1. **Evaluación formal (Test Dickey-Fuller aumentado - ADF):** ¡Recuerda! H_0 : serie no es estacionaria
2. **Aplicación de transformaciones según la variable**

Paso 3: Identificación y selección de modelo

Una vez que la serie transformada es estacionaria, se selecciona el enfoque de modelamiento:

- **Modelos Univariados:**

- $ARIMA(p, d, q)$
- $SARIMA(p, d, q)(P, D, Q)_s$
- **Criterios de Selección:** Usa funciones de autocorrelación (ACF) y autocorrelación parcial (PACF), criterios de información (**AIC / BIC**) o automatización usando `auto_arima` de la librería `pmdarima` de Python.

- **Modelos Multivariados:** Este tipo de modelos no será revisado en el Curso.

Modelación univariada: De ARIMA a SARIMA

Para capturar la dinámica temporal y la estacionalidad de la serie, estructuramos el modelo en componentes clave:

Estructura Regular: $\text{ARIMA}(p, d, q)$

$\text{AR}(p)$ — Autorregresivo: Memoria e inercia de las ventas en periodos recientes (Y_{t-1}, Y_{t-2}).

$\text{I}(d)$ — Integración: Diferencias regulares necesarias para lograr estacionariedad en la serie ($d = 1$).

$\text{MA}(q)$ — Media Móvil: Efecto de shocks o eventos atípicos no anticipados del pasado reciente (ϵ_{t-1}).

Extensión Estacional: SARIMA(p, d, q) $\times$ (P, D, Q) $_s$

Aplicado en series con patrones cíclicos repetitivos, como las ventas a clientes Regulados:

$$\text{SARIMA} \underbrace{(p, d, q)}_{\text{no estacional}} \times \underbrace{(P, D, Q)_s}_{\text{patrón estacional interanual}}$$

s (Frecuencia): Número de periodos por año ($s = 12$ para mensual, $s = 4$ para trimestral).

D (Diferencia estacional): Evalúa el cambio interanual respecto al mismo mes del año anterior ($\Delta_{12}Y_t = Y_t - Y_{t-12}$).

P y Q : Rezagos autorregresivos y de media móvil aplicados directamente a bloques estacionales (12, 24 o 36 meses).

Especificación de un ARMA(p, q):

$$Y_t = c + \sum_{i=1}^p \phi_i Y_{t-i} + \epsilon_t + \sum_{j=1}^q \theta_j \epsilon_{t-j}$$

donde c es la constante/intercepto, ϕ_i son los coeficientes autorregresivos, θ_j los coeficientes de media móvil y ϵ_t el término de error.

Criterios de Información

Permiten seleccionar el modelo con el número de parámetros que minimiza el valor del criterio de información:

Criterio de Akaike (AIC — Akaike Information Criterion)

Prioriza la capacidad predictiva.

$$AIC = \ln(\hat{\sigma}^2) + \frac{2k}{T}$$

Criterio Bayesiano (BIC — Bayesian Information Criterion)

Prioriza la parsimonia (simplicidad) del modelo.

$$BIC = \ln(\hat{\sigma}^2) + \frac{k}{T} \ln T$$

donde $\hat{\sigma}^2$ es la varianza de los residuos (suma de los residuos al cuadrado dividido por el número de observaciones), k es el número total de parámetros estimados y T es el número de observaciones.

Uso de Python: `auto_arima`

Funciones como `pmdarima.auto_arima` evalúan múltiples combinaciones de rezagos y devuelven automáticamente la especificación que minimiza el criterio seleccionado (`information_criterion='aic'` o `'bic'`).

Paso 4: Estimación, validación y evaluación

- **Validación out-of-sample:** Para evaluar la capacidad predictiva real de un modelo sin sesgo retrospectivo, la muestra total se divide estrictamente en dos bloques:
 - Muestra de Entrenamiento (train set): Ajuste de parámetros y optimización vía `auto_arima`.
 - Muestra de Prueba (test set): Evaluación del desempeño fuera de muestra.
- **Diagnóstico de residuos:** Los residuos del modelo ($e_t = Y_t - \hat{Y}_t$) no deben guardar información del pasado. Aplicar el test de **Ljung-Box**.
- **Métricas de evaluación** (*MAE*, *RMSE*)

Un modelo no se juzga por lo bien que explica el pasado (in-sample), sino por lo bien que anticipa el futuro (out-of-sample).

¿Cómo avanzamos en el tiempo sobre el test set?

Split por bloque fijo: El modelo se entrena una sola vez con el pasado y predice todo el bloque futuro. Útil para evaluaciones estáticas a mediano plazo.

Ventana rodante (rolling window): Mantiene constante el tamaño del bloque de entrenamiento. Avanza mes a mes descartando el dato más antiguo e incorporando el real más reciente ($t + 1$). Es muy útil en entornos volátiles, donde la información muy antigua ya no es relevante por cambios estructurales.

Ventana expansiva (expanding window): El punto de inicio queda fijo y el conjunto de entrenamiento crece acumulando toda la historia disponible. Se recomienda usar en casos donde acumular más historia ayuda a estimar mejor la tendencia de largo plazo.

Test de Ljung-Box

Permite evaluar si los errores de predicción del modelo (residuos) se comportan como ruido blanco o si aún queda patrón de autocorrelación no capturado.

H_0 : Los residuos no están autocorrelacionados

H_1 : Existe autocorrelación en los residuos

Revisa el *p-value* del Test de Ljung-Box que aparece como $\text{Prob}(Q)$ en el resultado que entrega Python.

$\text{Prob}(Q) > \alpha$: No se rechaza H_0

$\text{Prob}(Q) < \alpha$: Se rechaza H_0

Métricas de evaluación

Error absoluto medio (MAE — Mean Absolute Error)

Mide la magnitud promedio de los errores de pronóstico en las mismas unidades de la variable original, asignando el mismo peso a todas las desviaciones.

$$\text{MAE} = \frac{1}{n} \sum_{t=1}^n |y_t - \hat{y}_t|$$

Raíz del error cuadrático medio (RMSE — Root Mean Squared Error)

Mide la desviación estándar de los errores de predicción, penalizando con mayor severidad las desviaciones o errores de gran magnitud al elevarlas al cuadrado.

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{t=1}^n (y_t - \hat{y}_t)^2}$$

Paso 5: Generación de pronósticos

- **Pronósticos a un período** (*one-step-ahead*) es aquel que se genera únicamente para la siguiente observación.
- **Pronóstico a múltiples períodos** (*multi-step-ahead*) son aquellos que se elaboran para $1, 2, 3, \dots, s$ pasos hacia adelante, de modo que el horizonte de predicción abarca los próximos s períodos

Modelando S&P 500: Selección por AIC vs. BIC

```
Modelo óptimo por AIC: ARIMA(2, 0, 0)
SARIMAX Results
=====
Dep. Variable:      y      No. Observations:      1748
Model:      SARIMAX(2, 0, 0)      Log Likelihood      5210.072
Date:      Fri, 25 Sep 2026      AIC      -10412.143
Time:      18:25:36      BIC      -10390.278
Sample:      0      HQIC      -10404.060
      - 1748
Covariance Type:      opg
=====
              coef      std err      z      P>|z|      [0.025      0.975]
-----
intercept      0.0005      0.000      1.535      0.125      -0.000      0.001
ar.L1      -0.1447      0.011     -13.668      0.000      -0.165     -0.124
ar.L2      0.0799      0.010      8.164      0.000      0.061      0.099
sigma2      0.0002      2.08e-06     72.403      0.000      0.000      0.000
=====
Ljung-Box (L1) (Q):      0.00      Jarque-Bera (JB):      10619.42
Prob(Q):      0.96      Prob(JB):      0.00
Heteroskedasticity (H):      0.44      Skew:      -0.84
Prob(H) (two-sided):      0.00      Kurtosis:      14.96
=====

Warnings:
[1] Covariance matrix calculated using the outer product of gradients (complex-step).
```

```
Modelo óptimo por BIC: ARIMA(2, 0, 0)
SARIMAX Results
=====
Dep. Variable:      y      No. Observations:      1748
Model:      SARIMAX(2, 0, 0)      Log Likelihood      5208.669
Date:      Fri, 25 Sep 2026      AIC      -10411.339
Time:      18:25:36      BIC      -10394.940
Sample:      0      HQIC      -10405.277
      - 1748
Covariance Type:      opg
=====
              coef      std err      z      P>|z|      [0.025      0.975]
-----
ar.L1      -0.1430      0.010     -14.058      0.000      -0.163     -0.123
ar.L2      0.0816      0.009      8.634      0.000      0.063      0.100
sigma2      0.0002      2.02e-06     74.732      0.000      0.000      0.000
=====
Ljung-Box (L1) (Q):      0.01      Jarque-Bera (JB):      10634.48
Prob(Q):      0.91      Prob(JB):      0.00
Heteroskedasticity (H):      0.44      Skew:      -0.83
Prob(H) (two-sided):      0.00      Kurtosis:      14.97
=====

Warnings:
[1] Covariance matrix calculated using the outer product of gradients (complex-step).
```

Al evaluar los retornos logarítmicos del S&P 500, tanto el criterio AIC como el BIC coinciden en la estructura $\text{ARIMA}(2, 0, 0)$. Dado que el término constante carece de significancia estadística ($p = 0.125$), se decide removerlo por principio de parsimonia. Finalmente, la prueba de Ljung-Box ($p = 0.91$) confirma la ausencia de autocorrelación en los residuales (ruido blanco), validando el modelo $\text{ARIMA}(2, 0, 0)$ sin constante para la fase de pronóstico.

La especificación del modelo a utilizar es:

$$\hat{r}_{t+1} = -0.1430 r_t + 0.0816 r_{t-1}$$

El retorno esperado de mañana ($\hat{r}_{t+1}$) se calcula como una combinación lineal ajustada de los retornos observados en los dos días previos (r_t y r_{t-1}).

- Se aplica un esquema de ventana rodante (rolling window) a un paso adelante (1-step-ahead forecast).
- Se mantiene fija la estructura óptima seleccionada **ARIMA(2, 0, 0)** sin constante.

¿Cómo se obtiene el precio predicho del S&P 500 en niveles?

Matemáticamente, la relación entre el retorno logarítmico proyectado $\hat{r}_{t+1}$ y el precio real de hoy P_t es:

$$\hat{r}_{t+1} = \ln \left(\frac{\hat{P}_{t+1}}{P_t} \right)$$

Despejando el precio proyectado para el día siguiente ($\hat{P}_{t+1}$):


$$\hat{P}_{t+1} = P_t \cdot e^{\hat{r}_{t+1}}$$

Evaluación de pronósticos de S&P500

RMSE: 64.0752

MAE: 45.1826

S&P 500: Pronóstico en niveles out-of-sample (one-step-ahead)



Si intentas hacer un pronóstico multi-step (por ejemplo, a 30 días vista sin ir actualizando la ventana rodante con datos reales día a día), entonces el valor predicho para el S&P500 tenderá a congelarse en un nivel plano y constante a partir del tercer o cuarto día. Esto sucede porque los retornos esperados convergen rápidamente a cero en ausencia de constante ($\mu = 0$), provocando que el modelo pierda toda su capacidad predictiva en horizontes de mediano y largo plazo.

Modelando VIX: Selección por AIC vs. BIC

```
Modelo óptimo por AIC: ARIMA(2, 0, 3)
SARIMAX Results
=====
Dep. Variable:      y      No. Observations:      1752
Model:              SARIMAX(2, 0, 3)  Log Likelihood      -3707.142
Date:              Fri, 25 Sep 2026  AIC              7428.285
Time:              18:27:15  BIC              7466.564
Sample:            0      HQIC              7442.434
                    - 1752
Covariance Type:    opg
=====
              coef      std err      z      P>|z|      [0.025      0.975]
-----
intercept      1.0804      0.204      5.284      0.000      0.680      1.481
ar.L1           0.1349      0.043      3.123      0.002      0.050      0.220
ar.L2           0.8101      0.043     18.780      0.000      0.726      0.895
ma.L1           0.6576      0.044     14.864      0.000      0.571      0.744
ma.L2          -0.0743      0.020     -3.789      0.000     -0.113     -0.036
ma.L3           0.1367      0.013     10.583      0.000      0.111      0.162
sigma2          4.0245      0.049     82.323      0.000      3.929      4.120
=====
Ljung-Box (L1) (Q):      0.02  Jarque-Bera (JB):      65619.39
Prob(Q):                0.89  Prob(JB):                0.00
Heteroskedasticity (H):  0.30  Skew:                3.28
Prob(H) (two-sided):    0.00  Kurtosis:            32.25
=====

Warnings:
[1] Covariance matrix calculated using the outer product of gradients (complex-step).
```

```
Modelo óptimo por BIC: ARIMA(2, 0, 3)
SARIMAX Results
=====
Dep. Variable:      y      No. Observations:      1752
Model:              SARIMAX(2, 0, 3)  Log Likelihood      -3707.142
Date:              Fri, 25 Sep 2026  AIC              7428.285
Time:              18:27:15  BIC              7466.564
Sample:            0      HQIC              7442.434
                    - 1752
Covariance Type:    opg
=====
              coef      std err      z      P>|z|      [0.025      0.975]
-----
intercept      1.0804      0.204      5.284      0.000      0.680      1.481
ar.L1           0.1349      0.043      3.123      0.002      0.050      0.220
ar.L2           0.8101      0.043     18.780      0.000      0.726      0.895
ma.L1           0.6576      0.044     14.864      0.000      0.571      0.744
ma.L2          -0.0743      0.020     -3.789      0.000     -0.113     -0.036
ma.L3           0.1367      0.013     10.583      0.000      0.111      0.162
sigma2          4.0245      0.049     82.323      0.000      3.929      4.120
=====
Ljung-Box (L1) (Q):      0.02  Jarque-Bera (JB):      65619.39
Prob(Q):                0.89  Prob(JB):                0.00
Heteroskedasticity (H):  0.30  Skew:                3.28
Prob(H) (two-sided):    0.00  Kurtosis:            32.25
=====

Warnings:
[1] Covariance matrix calculated using the outer product of gradients (complex-step).
```

Al evaluar la serie del VIX, tanto el criterio AIC como el BIC coinciden en la estructura ARIMA(2, 0, 3). La prueba de Ljung-Box ($p = 0.89$) confirma la ausencia de autocorrelación en los residuales (ruido blanco), validando el modelo ARIMA(2, 0, 3) con constante para la fase de pronóstico.

La especificación del modelo a utilizar es:

$$\widehat{\text{VIX}}_{t+1} = 1.0804 + 0.1349 \text{VIX}_t + 0.8101 \text{VIX}_{t-1} + 0.6576 \epsilon_t - 0.0743 \epsilon_{t-1} + 0.1367 \epsilon_{t-2}$$


El valor esperado del VIX para mañana ($\widehat{\text{VIX}}_{t+1}$) se calcula como una combinación lineal del nivel de base (intercepto), los valores observados en los dos días previos (VIX_t y VIX_{t-1}) y las innovaciones o choques recientes del mercado (ϵ_t , ϵ_{t-1} y ϵ_{t-2}).

Evaluación de pronóstico de VIX

RMSE: 1.5060

MAE: 1.0830

VIX: Pronóstico en niveles out-of-sample (one-step-ahead)



Modelando ventas de energía a clientes regulados: Selección por AIC vs. BIC

Modelo óptimo por AIC: ARIMA(0, 1, 0)

SARIMAX Results

```
=====
Dep. Variable:          y      No. Observations:          72
Model:          SARIMAX(0, 1, 0)x(1, 1, 0, 12)  Log Likelihood          50.254
Date:          Fri, 25 Sep 2026  AIC          -96.508
Time:          18:27:24  BIC          -92.352
Sample:          01-01-2019  HQIC          -94.886
          - 12-01-2024
```

Covariance Type: opg

```
=====
              coef      std err          z      P>|z|      [0.025      0.975]
-----
ar.S.L12      -0.4912      0.138      -3.564      0.000      -0.761      -0.221
sigma2         0.0101      0.002       5.771      0.000       0.007      0.013
=====
```

```
Ljung-Box (L1) (Q):          0.10  Jarque-Bera (JB):          3.55
Prob(Q):          0.75  Prob(JB):          0.17
Heteroskedasticity (H):      0.89  Skew:          0.44
Prob(H) (two-sided):      0.81  Kurtosis:          3.82
=====
```

Warnings:

[1] Covariance matrix calculated using the outer product of gradients (complex-step).

Modelo óptimo por BIC: ARIMA(0, 1, 0)

SARIMAX Results

```
=====
Dep. Variable:          y      No. Observations:          72
Model:          SARIMAX(0, 1, 0)x(1, 1, 0, 12)  Log Likelihood          50.254
Date:          Fri, 25 Sep 2026  AIC          -96.508
Time:          18:27:24  BIC          -92.352
Sample:          01-01-2019  HQIC          -94.886
          - 12-01-2024
```

Covariance Type: opg

```
=====
              coef      std err          z      P>|z|      [0.025      0.975]
-----
ar.S.L12      -0.4912      0.138      -3.564      0.000      -0.761      -0.221
sigma2         0.0101      0.002       5.771      0.000       0.007      0.013
=====
```

```
Ljung-Box (L1) (Q):          0.10  Jarque-Bera (JB):          3.55
Prob(Q):          0.75  Prob(JB):          0.17
Heteroskedasticity (H):      0.89  Skew:          0.44
Prob(H) (two-sided):      0.81  Kurtosis:          3.82
=====
```

Warnings:

[1] Covariance matrix calculated using the outer product of gradients (complex-step).

El modelo seleccionado es un SARIMA $(0, 1, 0) \times (1, 1, 0)_{12}$. La estacionalidad de la serie de ventas reguladas se captura de dos formas: primero, mediante una diferencia estacional interanual ($D = 1, s = 12$) que remueve el ciclo anual; y segundo, mediante un parámetro autorregresivo estacional ($AR(1)_s = -0.4912$) altamente significativo ($p < 0.05$) que modela la inercia del mismo mes del año previo. La prueba de Ljung-Box ($p = 0.75$) valida la ausencia de autocorrelación en los residuales.

La especificación del modelo a utilizar es:

$$Y_t = Y_{t-1} + Y_{t-12} - Y_{t-13} - 0.4912 \cdot (Y_{t-12} - Y_{t-13} - Y_{t-24} + Y_{t-25}) + \epsilon_t$$

Reagrupando términos,


$$Y_t = Y_{t-1} + 0.5088Y_{t-12} - 0.5088Y_{t-13} + 0.4912Y_{t-24} - 0.4912Y_{t-25} + \epsilon_t$$

Evaluación de pronósticos de ventas a clientes regulados

RMSE: 0.0981 TWh

MAE: 0.0772 TWh

Ventas a clientes regulados: Pronóstico out-of-sample mensual (one-step-ahead)



Ventajas de los modelos analizados

Requerimiento mínimo de datos: Solo requieren la historia de la propia serie (Y_t). Ideal cuando no se dispone de variables exógenas confiables o en tiempo real.

Flexibilidad para capturar dinámicas temporales: Combina de forma óptima la inercia del pasado (AR), los shocks recientes (MA) y la estacionalidad interanual (SARIMA).

Construcción de intervalos de predicción explícitos: Proporcionan una estimación probabilística y matemática precisa de la incertidumbre asociada a los pronósticos dentro o fuera de la muestra.

Limitaciones de los modelos analizados

Horizonte predictivo de corto plazo: A largo plazo, las proyecciones tienden a la media o a una tendencia lineal constante, perdiendo precisión ante quiebres estructurales (ej. crisis geopolíticas o reformas regulatorias).

Supuesto de homocedasticidad (varianza constante): No capturan por sí solos la aglomeración de volatilidad (volatility clustering) en series financieras.

Sensibilidad a parámetros y calibración: Exigen una validación rigurosa de estacionariedad (**ADF**) y ruido blanco (**Ljung-Box**). Un modelo mal especificado degrada rápidamente el pronóstico fuera de muestra.